

Méthodes adaptatives multi-niveaux

Partie 1 : Le cadre statique

Tony Lelièvre, slides préparés par Arnaud Guyader

MODAL Math App SNA

3 avril 2026

La cadre statique : Estimation de probabilité

- Soit X une variable aléatoire dans $\mathbb{R}^d$ que l'on sait simuler.
- Soit $S : \mathbb{R}^d \rightarrow \mathbb{R}$ une fonction évaluable en tout point.
- Hypothèse : on suppose la loi de $Y := S(X)$ sans atome.
- **But** : pour q fixé, on veut estimer

$$p := \mathbb{P}(Y > q) = \mathbb{P}(S(X) > q).$$

- Difficulté : $p > 0$ mais très faible.
- Rappel : une méthode Monte-Carlo standard est inefficace, puisque

$$\sqrt{n}(\hat{p}_n^{MC} - p) \xrightarrow[n \rightarrow \infty]{d} \mathcal{N}(0, p(1-p)),$$

donc il faut $n \gg 1/p$ pour une évaluation précise de p .

Méthode multi-niveaux

- Niveaux : soit J fixé et $-\infty = L_0 < L_1 < \dots < L_J = q$.
- **Formule de Bayes** : en notant $p_j := \mathbb{P}(Y > L_j | Y > L_{j-1})$, on a

$$p = p_1 \dots p_J$$

- **Principe** : p est très faible mais les p_j ne le sont pas.
- **Cas idéal** : si l'on sait estimer par MC standard chaque p_j par $\hat{p}_{j,n}^{MC}$, alors on estime p par

$$\hat{p}_n := \hat{p}_{1,n}^{MC} \dots \hat{p}_{J,n}^{MC}.$$

- Pour un échantillon de taille n , à chaque étape, on sait que

$$\sqrt{n}(\hat{p}_{j,n}^{MC} - p_j) \xrightarrow[n \rightarrow \infty]{d} \mathcal{N}(0, p_j(1 - p_j)).$$

- Méthode Delta :

$$\sqrt{n}(\ln \hat{p}_{j,n}^{MC} - \ln p_j) \xrightarrow[n \rightarrow \infty]{d} \mathcal{N}(0, (1 - p_j)/p_j).$$

Cas idéal, J fixé

- Si les $(\hat{p}_{j,n}^{MC})_j$ sont indépendants, la méthode Delta donne

$$\sqrt{n} \frac{\hat{p}_n - p}{p} \xrightarrow[n \rightarrow \infty]{d} \mathcal{N} \left(0, \sum_{j=1}^J \frac{1 - p_j}{p_j} \right).$$

- **Question** : pour J fixé, déterminer les p_j de façon à minimiser

$$\sum_{j=1}^J \frac{1 - p_j}{p_j} \text{ avec } \prod_{j=1}^J p_j = p \text{ fixée.}$$

- **Réponse** : $p_1 = \dots = p_J = p^{1/J} =: p_0$.
- **Bilan** : dans un cadre idéal, pour J fixé, nous avons donc

$$\sqrt{n} \frac{\hat{p}_n - p}{p} \xrightarrow[n \rightarrow \infty]{d} \mathcal{N} \left(0, J \frac{1 - p_0}{p_0} \right).$$

Cas idéal, choix de J

- Nombre de niveaux : $J = \ln p / \ln p_0$.
- Variance asymptotique :

$$\varphi(p_0) := \frac{\ln p}{\ln p_0} \times \frac{1 - p_0}{p_0}.$$

- Minimisation : φ décroissante sur $[p, 1[$, avec

$$\lim_{p_0 \rightarrow 1^-} \varphi(p_0) = -\ln p.$$

- **Question** : comment faire $p_0 \rightarrow 1^-$ en pratique ?
- **Réponse** : algorithme de la dernière particule.

Algorithme de la dernière particule (cas idéal)

- Initialisation : générer $(X_1^0, X_2^0, \dots, X_n^0)$ i.i.d. selon $\mathcal{L}(X)$.
- Pour $j = 0, 1, 2, \dots$, soit $L_j = \min(S(X_1^j), \dots, S(X_n^j))$ et $\forall m \in \{1, \dots, n\}$:

$$X_m^{j+1} = \begin{cases} X_m^j & \text{si } S(X_m^j) > L_j \\ X^* \sim \mathcal{L}(X|S(X) > L_j) & \text{si } S(X_m^j) = L_j \end{cases}$$

avec, sachant L_j , X^* indépendant de $\{X_1^j, \dots, X_n^j\}$.

- Règle d'arrêt : continuer jusqu'à $J_n := \min\{j : L_j > q\}$ et poser

$$\hat{p}_n := \left(1 - \frac{1}{n}\right)^{J_n}.$$

- Remarque : tout l'aléa vient du nombre d'étapes J_n .

Résultats : cadre idéal

- Nombre d'étapes : $J_n \sim \mathcal{P}(-n \ln p)$.
- Estimateur : $\hat{p}_n$ est à valeurs dans $\{1, (1 - 1/n), \dots\}$ avec

$$\mathbb{P} \left(\hat{p}_n = \left(1 - \frac{1}{n}\right)^j \right) = \frac{p^n (-n \ln p)^j}{j!}$$

- Conséquences : $\mathbb{E}[\hat{p}_n] = p$ et $\mathbb{V}(\hat{p}_n) = p^2 \left(p^{-\frac{1}{n}} - 1 \right)$.
- Normalité asymptotique :

$$\sqrt{n}(\hat{p}_n - p) \xrightarrow[n \rightarrow \infty]{d} \mathcal{N}(0, -p^2 \ln p).$$

- IC asymptotique à 95% :

$$\left[\hat{p}_n \left(1 \pm \frac{1.96 \sqrt{-\ln \hat{p}_n}}{\sqrt{n}} \right) \right].$$

Implémentation pratique

- Principe : le même que pour le **splitting** vu en Amphi 2.
- Rappel : le noyau P est réversible pour la loi μ de X si $\forall (x, x')$

$$\mu(dx)P(x, dx') = \mu(dx')P(x', dx).$$

- **Noyau tronqué** : soit $A_\ell := \{x, S(x) > \ell\}$ et $\forall x \in A_\ell$

$$P_\ell(x, dx') := P(x, dx')\mathbb{1}_{A_\ell}(x') + \delta_x(dx')P(x, A_\ell^c).$$

- Réversibilité : soit $\mu_\ell := \mathcal{L}(X|S(X) > \ell)$, alors P_ℓ est réversible pour μ_ℓ . En particulier, μ_ℓ est invariante pour P_ℓ .
- **Conséquence** : pour simuler $X^* \sim \mathcal{L}(X|S(X) > \ell)$, cloner une autre particule et lui appliquer P_ℓ un “grand” nombre de fois.

Implémentation pratique (suite)

- **Exemple** : si $Y = X \sim \mu = \mathcal{N}(0, 1)$, et $\rho = \mathbb{P}(X > q)$.
- **Noyau** : si $W \sim \mathcal{N}(0, 1)$ et W indépendant de X alors, $\forall \rho \in]0, 1[$, P est μ -réversible lorsque

$$P(x, dx') = \frac{e^{-\frac{(x' - \rho x)^2}{2(1 - \rho^2)}}}{\sqrt{2\pi(1 - \rho^2)}} dx' \iff X' = \rho X + \sqrt{1 - \rho^2} W.$$

- **Itérations** : Pour chaque niveau ℓ , appliquer T fois P_ℓ .
- **Compromis** :
 - si $\rho \approx 1^-$, peu de risques de rejet mais il faut T grand ;
 - si $\rho \approx 0^+$, proba de rejet élevée donc il faut là aussi T grand.
- **Question** : que faire lorsqu'on ne dispose pas a priori d'un noyau P réversible pour μ ?

Implémentation pratique (suite)

- Rappel : soit Q un noyau de transition et P le noyau de Metropolis-Hastings associé à Q et μ , alors P est μ -réversible.
- Hypothèse : $\mu(dx) = \mu(x)dx$ et $Q(x, dx') = q(x, x')dx'$.
- Exploration : soit X tel que $S(X) > \ell$, simuler $\tilde{X} \sim Q(X, \cdot)$.
- Rapport MH :

$$r_\ell(X, \tilde{X}) = \frac{\mu_\ell(\tilde{X})q(\tilde{X}, X)}{\mu_\ell(X)q(X, \tilde{X})} = \frac{\mu(\tilde{X})q(\tilde{X}, X)}{\mu(X)q(X, \tilde{X})} \mathbb{1}_{S(\tilde{X}) > \ell}.$$

- Nouvelle particule : soit $U \sim \mathcal{U}_{[0,1]}$, alors

$$X' = \tilde{X} \mathbb{1}_{U \leq r_\ell(X, \tilde{X})} + X \mathbb{1}_{U > r_\ell(X, \tilde{X})}.$$

- A chaque étape, itérer T fois cette procédure pour générer X^* .

Le cadre statique : Estimation de quantile

- Soit X une variable aléatoire dans $\mathbb{R}^d$ que l'on sait simuler.
- Soit $S : \mathbb{R}^d \rightarrow \mathbb{R}$ une fonction évaluable en tout point.
- Hypothèse : $Y := S(X)$ de densité f_Y avec $f_Y(q) > 0$.
- **But** : pour p fixé, on veut estimer

$$q := F_Y^{-1}(1 - p) \iff \mathbb{P}(Y > q) = p.$$

- Difficulté : $p > 0$ mais très faible.
- Rappel : l'estimateur Monte-Carlo standard $Y_{(\lceil n(1-p) \rceil, n)}^{MC}$ est fortement consistant et vérifie

$$\sqrt{n} \left(Y_{(\lceil n(1-p) \rceil, n)}^{MC} - q \right) \xrightarrow[n \rightarrow \infty]{d} \mathcal{N} \left(0, \frac{p(1-p)}{f_Y(q)^2} \right).$$

Remarques sur le MC standard

- Explosion de la précision :

$$\sqrt{n} \frac{Y_{(\lceil n(1-p) \rceil, n)}^{MC} - q}{q} \xrightarrow[n \rightarrow \infty]{d} \mathcal{N}\left(0, \frac{p(1-p)}{q^{1/2} f_Y(q)^2}\right) =: \mathcal{N}(0, v(p)).$$

- Si $Y \sim \mathcal{E}(1)$, alors $v(p) = \frac{1-p}{p(-\ln p)^{1/2}}$.
- Si $Y \sim \mathcal{N}(0, 1)$, alors $v(p) \sim \frac{1}{p(-2 \ln p)^{5/4}}$ lorsque $p \rightarrow 0$.
- Intervalles de confiance : TCL précédent inutilisable en pratique, mais en notant (cf. TP2)

$$n^{\pm} := n \left(1 - p \pm 1.96 \frac{\sqrt{p(1-p)}}{\sqrt{n}} \right),$$

alors un IC de niveau asymptotique 95% est

$$\left[Y_{(\lceil n^{-} \rceil, n)}, Y_{(\lceil n^{+} \rceil, n)} \right].$$

Algorithme de la dernière particule (cas idéal)

- Initialisation : générer $(X_1^1, X_2^1, \dots, X_n^1)$ i.i.d. selon $\mathcal{L}(X)$.
- Pour $j = 1, 2, \dots$, soit $L_j = \min(S(X_1^j), \dots, S(X_n^j))$ et $\forall m \in \{1, \dots, n\}$:

$$X_m^{j+1} = \begin{cases} X_m^j & \text{si } S(X_m^j) > L_j \\ X^* \sim \mathcal{L}(X|S(X) > L_j) & \text{si } S(X_m^j) = L_j \end{cases}$$

avec, sachant L_j , X^* indépendant de $\{X_1^j, \dots, X_n^j\}$.

- Règle d'arrêt : continuer jusqu'à $j_n := \left\lceil \frac{\ln p}{\ln(1-n^{-1})} \right\rceil$ et poser

$$\hat{q}_n := L_{j_n}.$$

- Remarque : j_n n'est plus aléatoire, mais L_{j_n} l'est !

Résultats : cadre idéal

- Nombre d'étapes : $j_n = (-n \ln p)(1 + \mathcal{O}(n^{-1}))$.
- Normalité asymptotique :

$$\sqrt{n} \frac{\hat{q}_n - q}{q} \xrightarrow[n \rightarrow \infty]{d} \mathcal{N} \left(0, \frac{-p^2 \ln p}{q^{1/2} f_Y(q)^2} \right).$$

- Exemples : notons $v^*(p)$ cette variance asymptotique.
 - Si $Y \sim \mathcal{E}(1)$, alors $v^*(p) = (-\ln p)^{1/2} \ll \frac{1-p}{p(-\ln p)^{1/2}}$.
 - Si $Y \sim \mathcal{N}(0, 1)$, alors $v^*(p) \sim \frac{1}{2^{5/4}(-\ln p)^{1/4}} \ll \frac{1}{p(-2 \ln p)^{5/4}}$.
- IC asymptotique : TCL précédent inutilisable en pratique, mais en notant

$$j_n^\pm := -n \ln p \pm 1.96 \sqrt{-n \ln p}$$

alors un IC de niveau asymptotique 95% est $[L_{\lfloor j_n^- \rfloor}, L_{\lceil j_n^+ \rceil}]$.

Preuves : Processus de Poisson

- Fonction de risque cumulé : $\Lambda(y) := -\ln(1 - F_Y(y))$.
- Λ croissante, continue, $\Lambda(q) = -\ln p$, et $\Lambda(Y) \sim \mathcal{E}(1)$.
- Pour $j = 1$: soit $E_1 \sim \mathcal{E}(n)$

$$\Lambda(L_1) = \Lambda\left(\min_{1 \leq m \leq n} Y_m^1\right) = \min_{1 \leq m \leq n} (\Lambda(Y_m^1)) \stackrel{d}{=} E_1.$$

- Pour $j > 1$, risque cumulé conditionnel : $\forall y > L_{j-1}$,
 $\Lambda_j(y) := -\ln(\mathbb{P}(Y > y | Y > L_{j-1})) = \Lambda(y) - \Lambda(L_{j-1})$.
- Par la propriété d'absence de mémoire de la loi expo :

$$\Lambda_j(L_j) = \min_{1 \leq m \leq n} (\Lambda_j(Y_m^j)) \stackrel{d}{=} E_j,$$

avec $E_j \sim \mathcal{E}(n)$ indépendante de $E_1, \dots, E_{j-1}$.

- **Bilan** : les variables $T_j := \Lambda(L_j) \stackrel{d}{=} \sum_{k=1}^j E_k$ sont les temps d'arrivées d'un processus de Poisson d'intensité n .

Preuves : Propriétés de $\hat{p}_n$

- Nombre d'étapes :

$$J_n := \min\{j : L_j > q\} = \min\{j : T_j > -\ln p\} \sim \mathcal{P}(-n \ln p).$$

- Calculs directs : $\mathbb{E}[\hat{p}_n] = p$ et $\mathbb{V}(\hat{p}_n) = p^2 \left(p^{-\frac{1}{n}} - 1 \right)$.
- TCL : $J_n \stackrel{d}{=} \sum_{k=1}^n P_k$, avec $P_k \stackrel{\text{i.i.d.}}{\sim} \mathcal{P}(-\ln p)$, d'où

$$\sqrt{n} \left(\frac{J_n}{n} + \ln p \right) \xrightarrow[n \rightarrow \infty]{d} \mathcal{N}(0, -\ln p).$$

En particulier, J_n/n tend en probabilité vers $-\ln p$. De plus :

$$\ln \hat{p}_n = J_n \ln \left(1 - \frac{1}{n} \right) = -\frac{J_n}{n} (1 + \mathcal{O}(n^{-1})).$$

Preuves : Propriétés de $\hat{p}_n$ (suite)

- TCL (suite) :

$$\sqrt{n}(\ln p - \ln \hat{p}_n) = \sqrt{n} \left(\ln p + \frac{J_n}{n} \right) + \frac{J_n}{n} \mathcal{O}(n^{-1/2}).$$

- Lemme de Slutsky :

$$\sqrt{n}(\ln p - \ln \hat{p}_n) \xrightarrow[n \rightarrow \infty]{d} \mathcal{N}(0, -\ln p),$$

- Méthode Delta :

$$\sqrt{n}(\hat{p}_n - p) \xrightarrow[n \rightarrow \infty]{d} \mathcal{N}(0, -p^2 \ln p),$$

- Plug-in :

$$\sqrt{n} \frac{\hat{p}_n - p}{\hat{p}_n \sqrt{-\ln \hat{p}_n}} \xrightarrow[n \rightarrow \infty]{d} \mathcal{N}(0, 1).$$

Preuves : Propriétés de $\hat{q}_n$

- Rappel : $\hat{q}_n = L_{j_n}$, $j_n = \left\lceil \frac{\ln p}{\ln(1-n^{-1})} \right\rceil = -n \ln p (1 + \mathcal{O}(n^{-1}))$.
- Processus de Poisson : $n\Lambda(L_{j_n}) \stackrel{d}{=} \sum_{k=1}^{j_n} (nE_k)$, où $nE_k \sim \mathcal{E}(1)$.
- TCL :

$$\sqrt{j_n} \left(\frac{n\Lambda(L_{j_n})}{j_n} - 1 \right) \xrightarrow[n \rightarrow \infty]{d} \mathcal{N}(0, 1),$$

et le terme de gauche s'écrit aussi

$$\sqrt{\frac{n}{j_n}} [\sqrt{n} (\Lambda(L_{j_n}) + \ln p)] - \frac{n}{\sqrt{j_n}} \left(\ln p + \frac{j_n}{n} \right),$$

donc

$$\sqrt{n} (\Lambda(L_{j_n}) + \ln p) \xrightarrow[n \rightarrow \infty]{d} \mathcal{N}(0, -\ln p),$$

i.e.

$$\sqrt{n} (\Lambda(L_{j_n}) - \Lambda(q)) \xrightarrow[n \rightarrow \infty]{d} \mathcal{N}(0, -\ln p).$$

Preuves : Propriétés de $\hat{q}_n$ (suite)

- $\Lambda(\ell) := -\ln(1 - F_Y(\ell))$ donc $\Lambda'(q) = f_Y(q)/p$.
- Méthode Delta :

$$\sqrt{n}(\hat{q}_n - q) \xrightarrow[n \rightarrow \infty]{d} \mathcal{N}\left(0, \frac{-p^2 \ln p}{f_Y(q)^2}\right).$$

- IC : soit $N \sim \mathcal{P}(-n \ln p)$, alors $\forall j \geq 0$

$$\mathbb{P}(L_j \leq q < L_{j+1}) = \mathbb{P}(T_j \leq -\ln p < T_{j+1}) = \mathbb{P}(N = j).$$

On cherche donc le plus petit intervalle $[j_n^-, j_n^+]$ tel que

$$\sum_{j=j_n^-}^{j=j_n^+} \mathbb{P}(N = j) \geq 0,95.$$

- Approximation gaussienne : $N \approx \mathcal{N}(-n \ln p, -n \ln p)$.
- IC asymptotique : si $I_n = [-n \ln p \pm 1.96\sqrt{-n \ln p}]$, alors

$$\mathbb{P}(N \in I_n) \xrightarrow[n \rightarrow \infty]{} 0.95.$$

Quelques remarques

- Cas non idéal : $-p^2 \ln p$ est une borne inférieure de la variance obtenue **en pratique**, i.e. quand “ $T < \infty$ ”.
- Alternative : choisir $p_0 \in]0, 1[$ (e.g. $p_0 = 3/4$) et éliminer les $(1 - p_0)N$ dernières particules à chaque étape. Nouvel échantillon : à chaque étape, cloner des particules de score supérieur à ℓ et leur appliquer T fois le noyau P_ℓ . Pour $p = rp_0^j$ avec $p_0 < r \leq 1$, l'estimateur $\hat{p} := \hat{r}p_0^{\hat{j}}$ vérifie dans le cas idéal

$$\sqrt{n} \frac{\hat{p} - p}{p} \xrightarrow[n \rightarrow \infty]{d} \mathcal{N} \left(0, \frac{1-r}{r} + j \frac{1-p_0}{p_0} \right).$$

- **Article** : *Simulation and Estimation of Extreme Quantiles and Extreme Probabilities*, A. Guyader, N. Hengartner, and E. Matzner-Løber. Applied Mathematics & Optimization, 2011.