
MODÉLISATION STOCHASTIQUE D'UN CARNET D'ORDRES SIMULATION, ÉVÉNEMENTS RARES ET CALIBRATION

MODAL — Carnet d'ordres SNA

Résumé

Ce rapport présente l'ensemble de notre travail de modélisation stochastique d'un carnet d'ordres à cours limité (LOB). Le rapport est organisé en trois grandes parties. La **première partie** développe progressivement les modèles : de la marche aléatoire de Poisson au Hawkes couplé bid/ask, puis à la dynamique de prix sur quatre limites. La **deuxième partie** traite l'estimation des probabilités d'événements rares par Monte-Carlo, splitting AMS et importance sampling. La **troisième partie** couvre la calibration des paramètres par maximum de vraisemblance et la validation sur les données réelles du Bitcoin Black Thursday (mars 2020).

Table des matières

Introduction	4
I Du Poisson au Hawkes couplé : construction progressive du modèle de carnet d'ordres	4
1 Modèle de Poisson indépendant	5
1.1 Simulation exacte	5
1.2 Estimation Monte-Carlo du temps moyen d'atteinte de 0	5
1.3 Approximation diffusive	6
1.4 Loi inverse-gaussienne du temps d'atteinte de 0	7
1.5 Probabilité de ruine asymétrique $\mathbb{P}(\tau_a < \tau_b)$	9
1.6 Surface 3D du temps moyen $\mathbb{E}[\min(\tau_a, \tau_b)]$	10

2	Processus de Hawkes auto-excité	11
2.1	Modèle et propriétés stationnaires	11
2.2	Algorithme de simulation par thinning d'Ogata	12
2.3	Résultats numériques	13
3	Hawkes couplé bid/ask et processus auxiliaire	14
3.1	Couplage croisé exciteur	14
3.2	Comparaison des quatre régimes	16
3.3	Processus auxiliaire q_2 au niveau adjacent	17
3.4	Intensité λ_2^+ excitée par les décréments d'ask	17
4	Passage au prix : modèle à quatre limites	18
4.1	Architecture et mécanique du saut de prix	18
II	Estimation des probabilités d'événements rares : Monte-Carlo, splitting AMS et importance sampling	20
5	Limites du Monte-Carlo naïf en régime rare	21
6	Splitting multiniveau (AMS)	21
6.1	Algorithme AMS et estimateur	21
6.2	Distribution des états aux niveaux de splitting	23
6.3	Flash crash de profondeur k	24
7	Importance Sampling par basculement exponentiel	27
7.1	Principe du changement de mesure	27
7.2	Optimisation de θ^* et comparaison avec l'AMS	27
7.3	Comparaison directe CLT : AMS vs IS	29
III	Calibration par maximum de vraisemblance et confrontation aux données de marché	30
8	Calibration par maximum de vraisemblance	30
8.1	Log-vraisemblance du Hawkes bivarié à couplage croisé	30
8.2	Résultats numériques : validation synthétique	31
9	Application aux données réelles : Bitcoin Black Thursday	32
9.1	Contexte et mécanisme microstructural	32

9.2	Données : API Binance 1h	32
9.3	Calibration et estimation AMS	32
10	Tentative de modélisation du squeeze GameStop	33
	Conclusion	33

Introduction

Un *carnet d'ordres à cours limité* (LOB) est le mécanisme central par lequel les marchés financiers électroniques appariement les offres d'achat et de vente. À chaque instant, le carnet recense les volumes $q_b^{(k)}$ côté acheteur et $q_a^{(k)}$ côté vendeur pour chaque niveau de prix k . Le *mid-price* $p_0 = (\text{meilleur ask} + \text{meilleur bid})/2$ évolue par sauts discrets chaque fois que le meilleur niveau d'un côté s'épuise : c'est ce mécanisme d'épuisement qui est au cœur de ce projet.

La question centrale est : *quand et avec quelle probabilité l'un des deux côtés du carnet s'épuise-t-il avant l'autre ?* On s'intéresse donc aux temps d'atteinte

$$\tau_a = \inf\{t \geq 0 : q_{a,1}(t) = 0\}, \quad \tau_b = \inf\{t \geq 0 : q_{b,1}(t) = 0\},$$

et plus particulièrement à la probabilité $\mathbb{P}(\tau_a < \tau_b)$ et à la loi de $\min(\tau_a, \tau_b)$. Pour répondre à cette question, nous construisons le modèle par couches successives — du processus de Poisson indépendant jusqu'au Hawkes bivarié couplé sur quatre limites, calibré sur données réelles — et mobilisons quatre méthodes de simulation et d'estimation : Monte-Carlo, splitting multiniveau (AMS), importance sampling et maximum de vraisemblance.

Cadre paramétrique. Afin de rendre les comparaisons entre modèles cohérentes et reproductibles, les paramètres de simulation sont fixés une fois pour toutes (tableau 1).

Paramètre	Valeur	Rôle / justification
λ^+	1,2	Intensité d'insertion ; $\mu = \lambda^+ - \lambda^- = -0,8 < 0$ (drift négatif).
λ^-	2,0	Intensité d'annulation ; $\sigma^2 = \lambda^+ + \lambda^- = 3,2$.
q_0	10	Volume initial (régime fluide ; $\mathbb{E}[\tau]$ observable).
μ^-	2,0	Intensité de fond Hawkes $= \lambda^-$ (comparaison directe).
α	0,5	Gain d'excitation Hawkes ; $\rho = \alpha/\beta = 0,5 < 1$ (stabilité).
β	1,0	Taux de relaxation exponentielle.
a, b	0,8, 1,0	Excitation croisée vers le niveau adjacent q_2 .
M (MC)	10^3 – $1,2 \cdot 10^6$	Petit pour les figures exploratoires, très grand pour les contrôles rares.
N (AMS)	300 – $5 \cdot 10^5$	Particules splitting selon la section, avec grands N pour les événements rares.

Table 1 – Paramètres globaux. Le choix $\lambda^- > \lambda^+$ garantit un drift négatif, condition nécessaire pour que l'atteinte de zéro soit presque sûre.

Valeurs de référence. Ces paramètres impliquent, pour le modèle brownien limite : $\mathbb{E}[\tau]_{\text{BM}} = q_0/|\mu| = 12,5$ et $\text{Var}(\tau)_{\text{BM}} = q_0\sigma^2/|\mu|^3 = 62,5$. Pour le processus de Hawkes seul, l'intensité stationnaire vaut $\bar{\lambda}_\infty = (\mu^- \beta - \lambda^+ \alpha)/(\beta - \alpha) = 2,8$: ces trois quantités serviront de points d'ancrage tout au long du rapport.


Première partie

Du Poisson au Hawkes couplé : construction progressive du modèle de carnet d'ordres

1 Modèle de Poisson indépendant

1.1 Simulation exacte

Chaque côté évolue selon $q(t) = q_0 + N_t^+ - N_t^-$, où $N_t^\pm$ sont des processus de Poisson indépendants d'intensités $\lambda^\pm$, absorbés en zéro. La simulation est *exacte* : inter-événements $\sim \text{Exp}(\lambda^+ + \lambda^-)$, saut +1 avec proba $\lambda^+ / (\lambda^+ + \lambda^-)$.



(a) Deux réalisations simultanées (q_a haut, q_b bas). Le drift négatif est visible ; l'ask se vide avant le bid ici. *Horizontal : temps ; vertical : volume.*

(b) Trajectoire conjointe (q_b, q_a) dans le plan. Point rouge : (10,10) ; point vert : arrêt. *Axes : volumes bid et ask.*

Figure 1 – Modèle de Poisson indépendant.

1.2 Estimation Monte-Carlo du temps moyen d'atteinte de 0

L'estimateur empirique $\hat{T}_M = M^{-1} \sum_{i=1}^M \tau^{(i)}$ admet l'intervalle de confiance asymptotique (TCL) : $\text{IC}_{95\%} = \hat{T}_M \pm 1,96 \hat{\sigma}_M / \sqrt{M}$.

Sur le rerun du notebook : $\hat{T}_1 \text{ proc.} = 12,48$, $\text{IC} = [12,43; 12,53]$; $\hat{T}_{\min} = 8,47$, $\text{IC} = [8,44; 8,50]$.

1.3 Approximation diffusive

Proposition 1.1 (Convergence vers le mouvement brownien). Lorsque $q_0 \rightarrow \infty$ avec q_0/σ^2 fixé, la marche aléatoire $q(t)/\sqrt{q_0}$ converge en loi (au sens du TCL fonctionnel pour les processus de Poisson) vers le processus de diffusion

$$dQ_t = \mu dt + \sigma dW_t, \quad Q_0 = q_0, \quad \mu = \lambda^+ - \lambda^-, \quad \sigma = \sqrt{\lambda^+ + \lambda^-}.$$

En particulier, à horizon T fixé (sans absorption) : $q(T) \stackrel{d}{\approx} \mathcal{N}(q_0 + \mu T, \sigma^2 T)$.

Éléments de preuve. Par le TCL fonctionnel (Donsker), les processus recentrés $(N_t^\pm - \lambda^\pm t)/\sqrt{\lambda^\pm}$ convergent vers des mouvements browniens $W^\pm$ indépendants. La différence $N_t^+ - N_t^- - \mu t$ normalisée converge donc vers $\sqrt{\lambda^+ + \lambda^-} W_t$. $\square$

Validation numérique

Objectif. Vérifier que la distribution de $q(T)$ à horizon fixé converge bien vers la gaussienne prédite par le TCL fonctionnel, et quantifier l'écart résiduel dû à la discrétisation et à la taille finie de T .

Protocole. On simule $N = 10000$ trajectoires indépendantes de la marche de Poisson jusqu'à $T = 100$ avec les paramètres $\lambda^+ = 1,2$, $\lambda^- = 2,0$, $q_0 = 10$. La proposition prédit :

$$q(T) \stackrel{d}{\rightarrow} \mathcal{N}(\mu T, \sigma^2 T) \quad \text{avec} \quad \mu = \lambda^+ - \lambda^- = -0,8, \quad \sigma^2 = \lambda^+ + \lambda^- = 3,2.$$

Pour $T = 100$, on attend donc $q(100) \sim \mathcal{N}(-70, 320)$.

Résultats numériques.

Quantité	CLT (théorique)	Simulation ($N = 10000$)	Écart
$\mathbb{E}[q(T)]$	-70,00	-70,56	+0,8 %
$\text{std}(q(T))$	17,89	17,74	-0,8 %

Lecture de la figure. La figure ci-dessous superpose la densité gaussienne théorique (rouge) à l'histogramme empirique (bleu). Le chevauchement quasi-parfait des deux courbes confirme visuellement l'accord numérique.




Figure 2 – Distribution empirique de $q(T)$ (bleu) vs $\mathcal{N}(-70, 320)$ (rouge). *Horizontal : $q(T)$; vertical : densité.*

Interprétation. L'accord sub-pourcent sur la moyenne et l'écart-type confirme que dès $T = 100$ sauts, le régime asymptotique gaussien est pratiquement atteint. Le léger écart sur l'écart-type ($-0,8\%$) reste du même ordre que le bruit de simulation et les effets de discrétisation : les sauts valent ± 1 et $q_0 = 10$ est fini, alors que le CLT suppose une diffusion continue et $q_0 \rightarrow \infty$.

1.4 Loi inverse-gaussienne du temps d'atteinte de 0

Théorème 1.2 (Hitting time du mouvement brownien avec drift négatif). Soit $X_t = q_0 + \mu t + \sigma W_t$ avec $\mu < 0$. Le premier temps d'atteinte $\tau = \inf\{t \geq 0 : X_t = 0\}$ suit une loi *inverse-gaussienne* :

$$\tau \sim \text{IG}(\mu_{\text{IG}}, \lambda_{\text{IG}}), \quad \mu_{\text{IG}} = \frac{q_0}{|\mu|}, \quad \lambda_{\text{IG}} = \frac{q_0^2}{\sigma^2},$$

de densité $f_\tau(t) = \sqrt{\lambda_{\text{IG}}/(2\pi t^3)} \exp(-\lambda_{\text{IG}}(t - \mu_{\text{IG}})^2/(2\mu_{\text{IG}}^2 t))$.

Éléments de preuve. Par le théorème d'arrêt optionnel appliqué à la martingale $e^{2|\mu|X_t/\sigma^2}$, on obtient la transformée de Laplace de τ : $\mathbb{E}[e^{-s\tau}] = \exp(q_0(\mu - \sqrt{\mu^2 + 2s\sigma^2})/\sigma^2)$. Cette expression correspond exactement à la fonction génératrice des moments d'une loi $\text{IG}(\mu_{\text{IG}}, \lambda_{\text{IG}})$. $\square$

Validation numérique

Objectif. Vérifier que la loi du premier temps d'atteinte de zéro pour la marche de Poisson est bien approchée par la loi inverse-gaussienne $\text{IG}(\mu_{\text{IG}}, \lambda_{\text{IG}})$ avec $\mu_{\text{IG}} = q_0/|\mu| = 12,5$ et $\lambda_{\text{IG}} = q_0^2/\sigma^2 = 31,25$.

Protocole. On simule $N = 50000$ trajectoires Poisson ($\lambda^+ = 1,2$, $\lambda^- = 2,0$, $q_0 = 10$) jusqu'à l'atteinte de zéro, et on compare les moments empiriques aux valeurs théoriques de la loi IG.

Comparaison des moments.

Quantité	IG théorique	Simulation ($N = 50000$)	Écart relatif
$\mathbb{E}[\tau]$	12,500	12,517	+0,14 %
$\text{Var}(\tau)$	62,500	62,706	+0,33 %


La moyenne et la variance sont toutes deux restituées à moins de 0,2 % près. Le rerun ne montre donc pas de biais numérique significatif sur les deux premiers moments.

Test d'adéquation globale.


Test	Statistique D	p -valeur	Conclusion
Kolmogorov-Smirnov (IG vs simulation)	0,0055	0,0971	Non-rejet à 5 %

La statistique KS de 0,0055 est nettement inférieure au seuil critique, et la p -valeur de 0,0971 confirme qu'il n'y a aucune raison statistique de rejeter l'adéquation IG.

Visualisation.



(a) Histogramme des temps d'arrêt ($N = 50000$ réalisations). La forme asymétrique à droite est caractéristique de la loi IG. Horiz. : τ ; vert. : fréquence.



(b) Densité IG théorique (rouge) superposée à l'histogramme normalisé. Le pic et la queue droite coïncident. Horiz. : τ ; vert. : densité.

Figure 3 – Validation de la loi inverse-gaussienne pour $q_0 = 10$.

Convergence vers la loi inverse-gaussienne validée

La moyenne est restituée à +0,14 %, la variance à +0,33 %, et le test KS ne rejette pas l'adéquation ($p = 0,0971$). L'approximation diffusive est donc validée numériquement pour $q_0 = 10$.

1.5 Probabilité de ruine asymétrique $\mathbb{P}(\tau_a < \tau_b)$

Proposition 1.3 (Formule intégrale de la probabilité de ruine). Pour deux processus de Poisson indépendants de mêmes intensités :

$$p(q_0^a, q_0^b) = \mathbb{P}(\tau_a < \tau_b) = \int_0^\infty f_{\tau_a}(t) (1 - F_{\tau_b}(t)) dt,$$

où f_{τ_a} est la densité IG et F_{τ_b} la CDF IG correspondante.

Justification. Par indépendance et conditionnement sur la valeur de τ_a : $\mathbb{P}(\tau_a < \tau_b) = \mathbb{E}_{\tau_a}[\mathbb{P}(\tau_b > \tau_a \mid \tau_a)] = \int_0^\infty f_{\tau_a}(t)(1 - F_{\tau_b}(t)) dt$. L'intégrale est évaluée par quadrature de Gauss-Legendre (rapide, sans forme close). $\square$

Validation numérique

Objectif. On valide la formule de ruine asymétrique de la Proposition 1.3 en comparant, sur une grille systématique de conditions initiales, la valeur analytique $\mathbb{P}(\tau_a < \tau_b)$ obtenue par quadrature IG à l'estimation Monte-Carlo de référence.

Protocole.

- **Grille** : $(q_0^a, q_0^b) \in \{1, \dots, 10\}^2$, soit 100 paires de conditions initiales.
- **Paramètres Poisson** : $\lambda^+ = 1, 2$, $\lambda^- = 2, 0$ (drift commun négatif ; l'asymétrie vient des conditions initiales).
- **MC** : $M = 500$ trajectoires par point ; estimateur $\hat{p}_{MC} = n_{\tau_a < \tau_b} / M$.
- **Quadrature IG** : intégrale numérique de la Proposition 1.3 via les densités IG en 500 points de Gauss-Legendre.




Figure 4 – Validation de la formule de ruine asymétrique : MC (gauche), quadrature IG (centre), écart absolu (droite). Sur la diagonale ($q_0^a = q_0^b$), $\hat{p} \approx 1/2$ (symétrie parfaite). Erreur max. : 0,049. Axes : q_0^a , q_0^b ; couleur : probabilité / erreur.

Lecture de la figure. Les trois panneaux se lisent conjointement : le panneau gauche (MC) et le panneau central (quadrature IG) exhibent des gradients identiques — la probabilité croît vers

le coin inférieur gauche ($q_0^b \gg q_0^a$, bid épuisé en premier) et décroît vers le coin supérieur droit ($q_0^a \gg q_0^b$). Le panneau droit (écart) reste uniformément faible, sans structure spatiale marquée.

Résultats quantitatifs.

- **Diagonale** : $\hat{p}_{MC} = 0,497 \approx \frac{1}{2}$, cohérent avec la symétrie parfaite de la marche aléatoire.
- **Plage de variation** : de 0,05 (coin $q_0^b \gg q_0^a$) à 0,95 (coin $q_0^a \gg q_0^b$), confirmant que la formule couvre l'ensemble des régimes.
- **Erreur absolue max** : 0,049, à comparer à l'IC MC $2\sqrt{p(1-p)/M} \approx 0,044$. L'écart est donc entièrement attribuable au bruit de Monte-Carlo : aucune erreur systématique n'est détectable.

Formule de ruine IG validée sur toute la grille

La quadrature numérique de la Proposition 1.3 reproduit les estimations Monte-Carlo à l'erreur d'échantillonnage près ($M = 500$). La formule est donc opérationnelle sans simulation : pour tout couple (q_0^a, q_0^b) , $\mathbb{P}(\tau_a < \tau_b)$ est obtenu en temps constant par une simple intégrale numérique.

1.6 Surface 3D du temps moyen $\mathbb{E}[\min(\tau_a, \tau_b)]$




Figure 5 – Modèle Poisson. Gauche : $\mathbb{E}[\min(\tau_a, \tau_b)]$ avec IC 95 % (wireframes rouge et noir, $M = 300$). Droite : $\mathbb{P}(\tau_a < \tau_b)$. Axes x, y : q_0^a, q_0^b ; surface : valeur de la quantité.

Les surfaces présentent le comportement attendu : $\mathbb{E}[\min(\tau_a, \tau_b)]$ croît régulièrement avec les deux volumes initiaux, et la probabilité de ruine asymétrique respecte la symétrie diagonale ($p \approx 1/2$ lorsque $q_0^a = q_0^b$). Pour $M = 300$ trajectoires par point de grille, les intervalles de confiance restent de

l'ordre de $\pm 2\%$, ce qui valide ces surfaces comme outil opérationnel pour évaluer rapidement le risque d'épuisement en fonction des conditions initiales.

2 Processus de Hawkes auto-excité

2.1 Modèle et propriétés stationnaires

On remplace l'intensité constante λ^- par une intensité de Hawkes qui intègre la mémoire des événements passés :

$$\lambda^-(t) = \mu^- + \alpha \sum_{s \in \mathcal{N}^-, s < t} e^{-\beta(t-s)} - \alpha \sum_{s \in \mathcal{N}^+, s < t} e^{-\beta(t-s)}, \quad \rho = \alpha/\beta < 1,$$

où $\mathcal{N}^-$ (resp. $\mathcal{N}^+$) désigne les instants de *décrément* (annulations/exécutions) et d'*incrément* (nouvelles insertions) de la file. Chaque décrétement augmente instantanément λ^- de α (auto-excitation) ; chaque incrément la diminue de α (inhibition propre) ; entre deux événements λ^- relaxe vers μ^- au taux β .

Proposition 2.1 (Intensité stationnaire du processus de Hawkes). En régime stationnaire et sous la condition de stabilité $\rho < 1$, l'intensité moyenne du processus de Hawkes avec excitation par les annulations et inhibition par les insertions est :

$$\bar{\lambda}_{\infty}^- = \frac{\mu^- \beta - \lambda^+ \alpha}{\beta - \alpha} = \frac{2 \times 1 - 1,2 \times 0,5}{1 - 0,5} = 2,8.$$

Démonstration. En régime stationnaire, $\mathbb{E}[\lambda^-(t)] = \bar{\lambda}$ est constant. Sans clipping, la dynamique moyenne vérifie $0 = -\beta(\bar{\lambda} - \mu^-) + \alpha\bar{\lambda} - \alpha\lambda^+$: les annulations arrivent au taux moyen $\bar{\lambda}$ et augmentent l'intensité de α , tandis que les insertions arrivent au taux exogène λ^+ et la diminuent de α . En réarrangeant, on obtient $\bar{\lambda}(\beta - \alpha) = \mu^- \beta - \lambda^+ \alpha$, d'où le résultat. $\square$

Validation numérique

Objectif. Vérifier numériquement que $\lambda^-(t)$ converge vers le point fixe $\bar{\lambda}_{\infty}^- = 2,80$ prédit par la Proposition 2.1, et identifier la source de l'écart résiduel observé.

Protocole.

- Paramètres : $\mu^- = 2$, $\alpha = 0,5$, $\beta = 1$, $\lambda^+ = 1,2$, $q_0 = 10^6$ pour éviter l'absorption à zéro pendant la mesure.
- 200 trajectoires simulées jusqu'à $T = 2000$.
- Burn-in $t_0 = 200$ appliqué pour éliminer le régime transitoire avant de mesurer la moyenne temporelle de λ^- .
- La moyenne et l'erreur standard des moyennes temporelles sont ensuite comparées à $\bar{\lambda}_{\infty}^- = 2,80$.

Résultat numérique.

$$\bar{\lambda}_{\infty, \text{emp}}^- = 2,9649 \pm 0,0079 \quad \Rightarrow \quad \text{écart : } + 5,89 \%.$$

La figure ci-dessous montre la distribution empirique des moyennes temporelles : la masse est bien concentrée, mais le centre de la distribution se situe à *droite* de la valeur théorique (ligne rouge).




Figure 6 – Distribution empirique des moyennes temporelles de λ^- pour $T = 2000$ (200 trajectoires, burn-in 200). La ligne rouge marque $\bar{\lambda}_\infty^- = 2,8$; la distribution est décalée de +5,89 % à droite. *Horizontal : valeur moyenne de λ^- ; vertical : fréquence.*

Interprétation de l'écart.

Biais de troncature inhérent au thinning inhibitoire

L'écart de +5,89 % n'est pas du bruit : c'est un biais *systématique* dû au **clipping** de l'intensité. Lors d'une insertion, la mise à jour est $\lambda^- \leftarrow \max(\lambda_{\text{pre}}^- - \alpha, 0)$. Lorsque $\lambda_{\text{pre}}^- < \alpha$, la valeur est tronquée à zéro au lieu de devenir négative, ce qui brise l'équilibre du bilan de flux supposé dans la démonstration analytique — laquelle opère sur $\mathbb{R}$ sans contrainte. La troncature introduit donc un excès d'intensité moyenne non compensé, expliquant le décalage positif observé. Ce biais est documenté dans la littérature sur les Hawkes inhibitoires et ne peut pas être éliminé par un simple réglage des paramètres.

2.2 Algorithme de simulation par thinning d'Ogata

L'intensité $\lambda^-(t)$ étant bornée par morceaux entre deux événements, on simule par l'algorithme de thinning d'Ogata.

Algorithm 1 Thinning d'Ogata pour le Hawkes individuel


```

1:  $t \leftarrow 0, \lambda^- \leftarrow \mu^-$ 
2: while condition d'arrêt non atteinte do
3:    $\bar{\lambda} \leftarrow \max(\mu^-, \lambda^-), \Lambda \leftarrow \bar{\lambda} + \lambda^+$ 
4:    $\Delta t \sim \mathcal{E}(\Lambda), t' \leftarrow t + \Delta t$ 
5:    $\lambda_{\text{pre}}^- \leftarrow \mu^- + (\lambda^- - \mu^-)e^{-\beta(t' - t_{\text{last}})}$  ▷ relaxation entre deux événements
6:    $U \sim \mathcal{U}[0, 1]$ 
7:   if  $U < \lambda^+/\Lambda$  then
8:      $q \leftarrow q + 1, \lambda^- \leftarrow \max(\lambda_{\text{pre}}^- - \alpha, 0)$  ▷ insertion : inhibition
9:   else if  $U < (\max(\lambda_{\text{pre}}^-, 0) + \lambda^+)/\Lambda$  then
10:     $q \leftarrow q - 1, \lambda^- \leftarrow \lambda_{\text{pre}}^- + \alpha$  ▷ annulation : auto-excitation
11:   else  $\lambda^- \leftarrow \lambda_{\text{pre}}^-$  ▷ rejet
12:   end if
13:    $t \leftarrow t'$ 
14: end while

```

2.3 Résultats numériques

Le processus de Hawkes produit une dynamique qualitativement différente du cas Poisson : l'auto-excitation génère des avalanches d'annulations qui se manifestent sous forme de descentes rapides et abruptes de $q(t)$, interrompues par des périodes de stabilité relative lorsque l'intensité se détend vers μ^- .



(a) $q(t)$ — trajectoire type. *Horizontal : temps ; vertical : volume.* (b) $\lambda^-(t)$ correspondante. Pics après annulations, relaxation exponentielle entre événements. *Horizontal : temps ; vertical : intensité.*

Figure 7 – Dynamique du processus de Hawkes individuel. L'auto-excitation crée des avalanches d'annulations.

La figure 7 illustre le mécanisme d'avalanche : après une annulation, $\lambda^-(t)$ bondit d'une quantité α , puis relaxe exponentiellement vers μ^- au taux β . Si une nouvelle annulation survient pendant cette période de relaxation, le pic s'additionne, créant la possibilité de cascades. Cet effet modifie profondément la distribution du temps d'arrêt, comme le montre la figure suivante.




Figure 8 – Distribution empirique du temps d’arrêt sous Hawkes individuel (bleu) vs Poisson de fond (tiret). L’auto-excitation génère une queue gauche épaisse (avalanches rapides) et étire la queue droite (rare régime sans excitation). *Horizontal* : τ ; *vertical* : densité.

La comparaison avec le Poisson de fond (paramètre $\lambda^- = \mu^-$) met en évidence l’effet double de l’auto-excitation : les avalanches créent une masse supplémentaire pour les petites valeurs de τ (épuisements très rapides), tandis que les périodes de faible intensité entre cascades s’étendent la queue droite. La distribution du Hawkes est donc plus étalée et moins régulière que celle du Poisson.

3 Hawkes couplé bid/ask et processus auxiliaire

3.1 Couplage croisé excitateur

Les deux files (q_a, q_b) sont simulées conjointement. Chaque côté conserve la logique individuelle (auto-excitation par ses propres décréments, inhibition par ses propres incréments), et est de plus *excité par tout événement de la file opposée*, qu’il s’agisse d’un départ ou d’une arrivée :

$$\lambda_a^-(t) = \mu_a^- + \alpha \sum_{s \in \mathcal{D}_a, s < t} e^{-\beta(t-s)} - \alpha \sum_{s \in \mathcal{A}_a, s < t} e^{-\beta(t-s)} + \alpha \sum_{s \in \mathcal{C}_b, s < t} e^{-\beta(t-s)},$$

où $\mathcal{D}_a/\mathcal{A}_a$ sont les décréments/incréments ask et $\mathcal{C}_b = \mathcal{D}_b \cup \mathcal{A}_b$ regroupe *tous* les événements bid. Symétriquement pour λ_b^- (avec $\mathcal{C}_a = \mathcal{D}_a \cup \mathcal{A}_a$). Ce couplage est cohérent avec la microstructure : toute activité côté bid — insertions comme annulations — signale un déséquilibre qui excite également la dynamique côté ask.

Pour la simulation du système joint, l’algorithme de thinning d’Ogata est étendu en maintenant une borne globale sur l’intensité totale : $\bar{\Lambda} = \lambda_a^- + \lambda_b^- + \lambda_a^+ + \lambda_b^+$. À chaque pas de temps, un événement candidat est tiré selon cette borne globale, puis attribué à l’un des quatre flux (annulation ask, annulation bid, insertion ask, insertion bid) proportionnellement aux intensités effectives du moment, avec rejet si le candidat tombe dans le complément. Cette approche est exacte et préserve intégralement la mémoire Hawkes des deux files.




Figure 9 – Hawkes couplé ($\mu_a^- = \mu_b^- = 2$). Le couplage concentre la distribution et réduit le temps moyen.




Figure 10 – Surfaces 3D pour le Hawkes couplé. Gauche : $\mathbb{E}[\min(\tau_a, \tau_b)]$ avec IC 95%. Droite : $\mathbb{P}(\tau_a < \tau_b)$. Axes x, y : q_0^a, q_0^b .

Au coin symétrique $(q_0^a, q_0^b) = (10, 10)$, le temps moyen d'épuisement vaut $\mathbb{E}[\min(\tau_a, \tau_b)] = 5,83$, à comparer à 8,32 pour le modèle de Poisson équivalent, soit une réduction de 30 % (facteur $\approx 0,70$). Ce raccourcissement s'explique par le couplage croisé excitateur : chaque événement sur l'une des files accélère simultanément l'autre, de sorte que les deux files tendent à s'épuiser plus rapidement ensemble que si elles évoluaient indépendamment.

3.2 Comparaison des quatre régimes

Modèle	Moyenne	Écart-type	Médiane	IQR
Poisson individuel	12,42	7,41	10,62	[7,3; 15,3]
Premier de deux Poisson	8,56	4,25	7,67	[5,6; 10,5]
Hawkes individuel	8,80	6,83	6,89	[4,2; 11,2]
Hawkes couplé bid/ask	5,91	3,55	5,11	[3,4; 7,4]

Table 2 – Comparaison des distributions de temps d'arrêt ($q_0 = 10$, $M = 1000$).




Figure 11 – Densités empiriques du temps d'arrêt pour les quatre régimes. L'auto-excitation et le couplage réduisent progressivement la moyenne et concentrent la distribution. *Horizontal* : τ ; *vertical* : densité.

Interprétation. Trois effets successifs ressortent de cette comparaison. Premièrement, le simple passage du processus de Poisson individuel au minimum de deux processus indépendants divise la moyenne par $\approx 1,45$: cet effet est purement combinatoire et ne fait intervenir aucune mémoire. Deuxièmement, le Hawkes individuel réduit davantage la médiane que la moyenne : les avalanches d'annulations génèrent des réalisations très courtes (queue gauche épaisse) qui abaissent la médiane, tandis que la queue droite reste épaisse car les rares trajectoires sans excitation sont longues. Troisièmement, le couplage croisé excitateur combine et amplifie ces deux effets : la réactivité mutuelle des deux files réduit à la fois la médiane et la moyenne, portant le facteur de réduction global à $\approx 2,1$ par rapport au Poisson individuel.

3.3 Processus auxiliaire q_2 au niveau adjacent

Lorsque la première limite ask s'épuise, le carnet d'ordres recharge automatiquement la deuxième limite : il est donc pertinent d'étudier la distribution du volume $q_{a,2}$ au niveau adjacent à l'instant d'épuisement $\tau = \min(\tau_a, \tau_b)$. On simule ce processus auxiliaire en parallèle, en conditionnant sur le côté qui s'épuise en premier. Cette distribution conditionnelle permet de calibrer l'état initial du prochain cycle lors du passage au modèle de prix à quatre limites.





Figure 12 – Loi conditionnelle discrète de $q_2(\tau)$ selon le côté s'épuisant, cas asymétrique $\mu_a^- = 2$, $\mu_b^- = 1,2$. Les barres représentent $\hat{P}(q_2(\tau) = m)$ et la ligne verticale la moyenne empirique. *Horizontal : q_2 à l'arrêt ; vertical : probabilité empirique.*

3.4 Intensité λ_2^+ excitée par les décréments d'ask

Un modèle plus réaliste consiste à coupler l'intensité d'insertion du niveau adjacent au flux des décréments de la première limite : chaque annulation ask signale une pression vendeuse croissante, ce qui stimule les market makers à replenish le niveau suivant. On modélise cela par $\lambda_2^+(t) = \mu_2^+ + \sum_{T_i^{\downarrow,a} < t} a e^{-b(t-T_i^{\downarrow,a})}$, où les coefficients a et b contrôlent respectivement l'amplitude et le taux de relaxation de cette excitation croisée vers le niveau adjacent.



(a) q_2 Poisson constant (référence). Les barres sont des masses discrètes. Horiz. : q_2 ; vert. : probabilité empirique.

(b) q_2 avec λ_2^+ excitée par décrets ask. Les masses se déplacent vers des volumes plus élevés. Horiz. : q_2 ; vert. : probabilité empirique.

Figure 13 – Loi conditionnelle discrète de $q_2(\tau)$, cas symétrique. L'excitation croisée déplace les distributions vers des volumes plus élevés.

4 Passage au prix : modèle à quatre limites

4.1 Architecture et mécanique du saut de prix

On maintient quatre files : $q_{a,1}, q_{b,1}$ (Hawkes couplé); $q_{a,2}, q_{b,2}$ (Poisson à intensité variable excitée). Les **intensités Hawkes sont continues entre cycles** : $(\lambda_a^{-\tau}, \lambda_b^{-\tau})$ initialisent le cycle suivant, préservant la mémoire. Lors de l'épuisement de $q_{a,1}$:

$$q_{a,1} \leftarrow q_{a,2}, \quad q_{a,2} \leftarrow q_0, \quad p_0 \uparrow \frac{\delta^p}{2}.$$

Proposition 4.1 (Dérive du mid-price et probabilité de hausse). Dans le modèle à quatre limites, la dérive du mid-price par cycle est :

$$\Delta p_0 = \frac{\delta^p}{2} (\mathbb{P}(\tau_a < \tau_b) - \mathbb{P}(\tau_b < \tau_a)) = \frac{\delta^p}{2} (2p - 1),$$

où $p = \mathbb{P}(\tau_a < \tau_b)$ est la probabilité de hausse par cycle. Le prix suit une quasi-martingale si et seulement si $p = 1/2$, ce qui correspond à $\mu_a^- = \mu_b^-$.

Démonstration. Chaque cycle induit un saut $+\delta^p/2$ avec probabilité p et $-\delta^p/2$ avec probabilité $1 - p$. L'espérance du saut vaut donc $\delta^p(p - 1/2)$, d'où la dérive. $\square$

Validation numérique

Objectif. Vérifier la formule $\Delta p_0 = \frac{\delta^p}{2}(2p - 1)$ dans deux régimes : symétrique (martingale attendue) et asymétrique (dérive non nulle). On simule 100 cycles dans chaque cas et on mesure la probabilité empirique de hausse $\hat{p}_\uparrow$ ainsi que la dérive effective du mid-price.

Paramètres des deux régimes.


Régime	μ_a^-	μ_b^-	p prédit	Dérive prédite
Symétrique	2,0	2,0	1/2	0
Asymétrique	3,0	1,5	$> 1/2$	> 0

Résultats numériques. Le rerun du notebook donne les valeurs suivantes :


Régime	$\hat{p}_\uparrow$	$\hat{p}_\downarrow$	dérive empirique
Symétrique	0,518	0,482	+0,0185
Asymétrique	0,738	0,262	+0,2375

Le régime symétrique reste donc quasi-martingale, tandis que $\mu_a^- > \mu_b^-$ augmente la fréquence d'épuisement ask et crée une dérive positive du mid-price.

Trajectoires.



(a) Cas symétrique. Le mid-price oscille sans tendance nette — cohérent avec une martingale. *Horiz. : temps ; vert. : mid-price (ticks).*




(b) Cas asymétrique. La tendance haussière est nettement visible dès les premiers cycles. *Horiz. : temps ; vert. : mid-price (ticks).*

Figure 14 — Trajectoires du mid-price sur 100 cycles. Le contraste entre les deux régimes est immédiatement visible : l'asymétrie μ_a^-/μ_b^- se traduit directement en dérive.

Dérive du mid-price conforme à la prédiction théorique


En cas symétrique, $\hat{p}_\uparrow = 0,518 \approx 1/2$ et la dérive est négligeable (+0,0185 tick/cycle), confirmant le comportement de martingale. En cas asymétrique, la dérive empirique de +0,2375 tick/cycle coïncide avec la prédiction $\hat{p}_\uparrow - 1/2 = 0,238$. Le modèle est donc *identifiable* depuis les trajectoires de prix : la seule observation de la dérive du mid-price permet d'inférer l'asymétrie μ_a^-/μ_b^- .



(a) Cas symétrique, 25 cycles. *Horiz. : temps ; vert. : volumes et prix.*

(b) Cas asymétrique, 25 cycles. Les épuisements ask sont plus fréquents. *Horiz. : temps ; vert. : volumes et prix.*

Figure 15 – État du carnet d'ordres (volumes des quatre limites + mid-price). Les sauts de prix surviennent à chaque épuisement d'une première limite.



(a) Distribution des sauts de prix, cas symétrique. *Horiz. : valeur du saut ; vert. : fréquence.*

(b) Distribution des sauts de prix, cas asymétrique. L'asymétrie $\mu_a^- > \mu_b^-$ favorise les hausses. *Horiz. : valeur du saut ; vert. : fréquence.*

Figure 16 – Distribution des incréments de mid-price par cycle.

Deuxième partie

Estimation des probabilités d'événements rares : Monte-Carlo, splitting AMS et importance sampling

La Partie I a établi que le modèle Hawkes couplé capture fidèlement la dynamique du carnet d'ordres. On s'intéresse maintenant à une question plus délicate : *comment estimer efficacement la probabilité d'événements qui surviennent rarement ?* Les sections de splitting de niveau peuvent viser indifféremment le côté ask ou le côté bid. Pour le flash crash et la comparaison AMS/IS finale, l'événement rare retenu est l'épuisement bid $\{\tau_b < \tau_a\}$ dans un régime où le bid est plus profond et moins fragile ($\mu_a^- > \mu_b^-$, $q_{b,0} > q_{a,0}$). Le Monte-Carlo naïf devient alors impraticable : il faudrait des millions de trajectoires pour obtenir une précision raisonnable. Nous comparons systématiquement Monte-Carlo, splitting multiniveau (AMS) et importance sampling en termes de variance et de coût computationnel, avant d'appliquer les méthodes les plus performantes au flash crash.

5 Limites du Monte-Carlo naïf en régime rare

Proposition 5.1 (Divergence du CV de l'estimateur naïf). Soit E un événement rare, par exemple $E = \{\tau_b < \tau_a\}$ dans les sections flash crash/IS, et soit $\hat{p}_{MC} = M^{-1} \sum_{i=1}^M \mathbf{1}_{E(i)}$ l'estimateur Monte-Carlo naïf de $p = \mathbb{P}(E)$. Alors :

$$CV(\hat{p}_{MC}) = \frac{\sqrt{\text{Var}(\hat{p}_{MC})}}{\hat{p}_{MC}} = \sqrt{\frac{1-p}{Mp}} \xrightarrow{p \rightarrow 0} \infty.$$

Le nombre de trajectoires nécessaires pour atteindre $CV = \epsilon$ est $M^* = \lceil (1-p)/(\epsilon^2 p) \rceil \sim 1/(\epsilon^2 p)$, inversement proportionnel à p .

Démonstration. $\hat{p}_{MC}$ est une moyenne de Bernoulli(p). Par le TCL, $\text{Var}(\hat{p}_{MC}) = p(1-p)/M$ et $CV = \sqrt{(1-p)/(Mp)}$. Quand p atteint les ordres 10^{-7} – 10^{-10} visés par le notebook haute qualité, le coût requis pour un CV raisonnable devient prohibitif. $\square$

6 Splitting multiniveau (AMS)

6.1 Algorithme AMS et estimateur

On décompose l'événement d'épuisement d'un côté $s \in \{a, b\}$ en Q_0^s paliers : $\mathcal{A}_k^{(s)} = \{q_{s,1} \leq k\}$, $k = Q_0^s - 1, \dots, 0$. Le notebook utilise ce même noyau pour le côté ask dans les distributions conditionnelles de $Q_{a,2}$, puis pour le côté bid dans les flash crashes.

Itération AMS. Pour $k = Q_0 - 1$ jusqu'à 0 :

1. Simuler chaque particule par thinning d'Ogata jusqu'à *succès* ($q_{s,1} = k$) ou *échec* (épuisement du côté opposé). Enregistrer $\hat{p}_k = n_k/N$.
2. Ré-échantillonner N copies parmi les n_k survivants (avec remise), héritant de l'état Hawkes complet $(\lambda_a^{\text{fin}}, \lambda_b^{\text{fin}}, t^{\text{fin}})$.

L'estimateur est $\hat{P}_{\text{AMS}} = \prod_{k=0}^{Q_0-1} \hat{p}_k$.

Proposition 6.1 (CLT de l'estimateur AMS par méthode delta). L'estimateur AMS vérifie, pour $N \rightarrow \infty$:

$$\sqrt{N} (\hat{P}_{\text{AMS}} - P) \xrightarrow{d} \mathcal{N}\left(0, P^2 \sum_{k=0}^{Q_0-1} \frac{1-p_k}{p_k}\right).$$

L'intervalle de confiance à 95 % est donc :

$$\hat{P}_{\text{AMS}} \pm 1,96 \hat{P}_{\text{AMS}} \sqrt{\frac{1}{N} \sum_k \frac{1-\hat{p}_k}{\hat{p}_k}}.$$

Démonstration. Notons $\hat{p}_k = n_k/N$ où $n_k \sim \text{Binomial}(N, p_k)$. Par indépendance asymptotique des niveaux, et par la méthode delta appliquée à $\log \hat{P}_{\text{AMS}} = \sum_k \log \hat{p}_k$: $\text{Var}(\log \hat{P}_{\text{AMS}}) \approx \sum_k \text{Var}(\log \hat{p}_k) = \sum_k (1-p_k)/(Np_k)$. La méthode delta donne ensuite $\text{Var}(\hat{P}_{\text{AMS}}) \approx P^2 \sum_k (1-p_k)/(Np_k)$, ce qui établit le résultat. $\square$

Validation numérique

Objectif. La Proposition 6.1 prédit $\sqrt{N}(\hat{P}_{\text{AMS}} - P) \xrightarrow{d} \mathcal{N}(0, \sigma_{\text{AMS}}^2)$. On souhaite valider deux implications pratiques de ce résultat :

1. L'écart-type empirique de $\hat{P}_{\text{AMS}}$ décroît en $1/\sqrt{N}$.
2. La largeur des IC à 95 % décroît également en $1/\sqrt{N}$ conformément à la théorie asymptotique.

Protocole.

- Régime rare cohérent avec le notebook corrigé : $\mu_a^- = 3,0$, $\mu_b^- = 1,2$, $q_{a,0} = 10$, $q_{b,0} = 12$, événement cible $\tau_b < \tau_a$.
- Pour chaque valeur de N , on effectue R répliques AMS indépendantes (les valeurs exactes N, R sont celles imprimées dans les cellules 70–71).
- On calcule l'écart-type empirique de $\hat{P}_{\text{AMS}}$ sur les répliques, et on trace les résultats en échelle log-log.




Figure 17 – Graphe semi-log (gauche) et log-log (droite) de l'écart-type de $\hat{P}_{\text{AMS}}$ en fonction de N sur l'événement bid rare $\tau_b < \tau_a$ ($\mu_a^- = 3.0, \mu_b^- = 1.2$). La droite log-log a une pente ≈ -0.5 , confirmant la décroissance en $1/\sqrt{N}$ prédite par la Proposition 6.1. Horiz. : N ; vert. : écart-type.

Figures et lecture.

Résultats quantitatifs. La pente log-log mesurée sur la figure est ≈ -0.5 , ce qui confirme la décroissance en $1/\sqrt{N}$ prédite par la méthode delta. Sur $R = 300$ réplifications AMS, le rerun donne $\hat{P}_{\text{AMS}} \approx 0.140$ et un coefficient de variation qui passe de 0,349 pour $N = 50$ à 0,048 pour $N = 3200$, soit une réduction d'un facteur 7 sur la plage considérée. Cette convergence rapide découle directement de la structure de l'algorithme : en décomposant l'événement rare en paliers successifs et en réorientant les particules vers des états progressivement plus proches de l'épuisement bid, l'AMS guide efficacement la simulation là où le Monte-Carlo naïf gaspillerait la quasi-totalité des trajectoires sur des réalisations ne franchissant pas le premier palier.

6.2 Distribution des états aux niveaux de splitting

À chaque palier k , les survivants portent un état complet $s_k = (\lambda_a^-(t_k), \lambda_b^-(t_k), q_{s,1}(t_k), t_k, \mathcal{D}_s^k)$ qui n'est pas égal à l'état non conditionné. On stocke les distributions empiriques $\hat{\pi}_k$ (phase hors-ligne), puis on bootstrapte depuis $\hat{\pi}_{k^*}$ pour simuler uniquement les derniers niveaux (phase en ligne) :

$$\hat{P}(\tau_s < \tau_{\bar{s}}) = \underbrace{\prod_{j=Q_0-1}^{k^*+1} \hat{p}_j}_{P_{\text{off}}} \times \hat{P}(\tau_s < \tau_{\bar{s}} \mid q_{s,1} \leq k^*).$$




Figure 18 — Splitting par niveaux, côté ask (cas asymétrique, $\mu_a^- = 3$, $\mu_b^- = 1,5$). Phase hors-ligne : 7,69 s ($N = 50000$); phase en ligne : 0,67 s ($N = 40000$).




Figure 19 — Splitting par niveaux, côté bid (mêmes paramètres). Symétrie ask/bid : le côté bid survit via le couplage croisé excitateur (λ_b^- augmentée).




Figure 20 — Distribution de $Q_{a,2}(\tau_a)$ estimée par AMS (bleu) et MC direct (orange).

6.3 Flash crash de profondeur k

Un flash crash de profondeur k est l'événement où le premier bid s'épuise k fois de suite avant que l'ask ne s'épuise : $FC_k = \{\tau_b^{(1)} < \tau_a, \tau_b^{(2)} < \tau_a, \dots, \tau_b^{(k)} < \tau_a\}$.

Proposition 6.2 (Non-indépendance des cycles Hawkes). Soit $p_1 = \mathbb{P}(\tau_b < \tau_a)$. Avec le modèle Hawkes à cycles continus :

$$P(\text{FC}_k) = \prod_{i=1}^k c_i, \quad c_i = P(\tau_b^{(i)} < \tau_a \mid \text{FC}_{i-1}).$$

En général $c_i \neq p_1$: la référence i.i.d. p_1^k n'est pas une borne, mais seulement un scénario sans mémoire. Dans le régime bid rare corrigé du notebook, les probabilités conditionnelles mesurées vérifient au contraire $c_1 \simeq 0,142$, $c_2 \simeq 0,043$, $c_3 \simeq 0,031$, etc., donc $P(\text{FC}_k) < p_1^k$ pour $k \geq 2$.


Argument. L'identité vient du conditionnement successif. La non-indépendance vient du fait que l'état final d'un cycle n'est pas réinitialisé : les intensités Hawkes $(\lambda_a^{-\text{fin}}, \lambda_b^{-\text{fin}})$ et le volume ask restant sont transportés vers le cycle suivant, tandis que le bid est reconstruit. Le signe de l'écart à p_1^k dépend donc du régime. Ici, après un épuisement bid rare, le bid repart plein alors que l'ask peut déjà être proche de zéro et que l'intensité ask a aussi été excitée par couplage croisé ; cela réduit les probabilités conditionnelles de nouveaux épuisements bid successifs. $\square$

Validation numérique

Objectif. Quantifier l'écart entre $P(\text{FC}_k)$ — estimé par AMS sous le modèle Hawkes à mémoire continue — et la prédiction naïve p_1^k (cycles i.i.d. Bernoulli). La Proposition 6.2 prédit surtout que les deux courbes ne doivent pas être confondues ; le signe de l'écart est une propriété du régime calibré, pas une loi universelle.

Protocole.

- $N = 2000$ particules AMS, $Q_0 = 10$ niveaux de splitting.
- Deux régimes : symétrique ($\mu_a^- = \mu_b^- = 2$) et asymétrique ($\mu_a^- = 3,0$, $\mu_b^- = 1,2$, $q_{a,0} = 10$, $q_{b,0} = 12$).
- Pour chaque régime, $p_1 = \hat{P}_{\text{AMS}}(\text{FC}_1)$ est estimé au préalable, puis p_1^k sert de référence Bernoulli.



(a) Cas symétrique. L'AMS (bleu) et la référence i.i.d. (orange) se séparent dès $k = 2$. Horiz. : k ; vert. : probabilité. (b) Cas asymétrique bid rare. L'écart s'amplifie; l'axe vertical est en échelle log pour visualiser les petites probabilités. Horiz. : k ; vert. : probabilité (log).

Figure 21 – Probabilité du flash crash de profondeur k sous Hawkes (AMS, bleu) vs modèle Bernoulli indépendant (orange). Dans le régime corrigé, la référence i.i.d. surestime les cascades bid profondes.

Figures.

Facteurs multiplicatifs (cas asymétrique). Le rerun donne $p_1 \simeq 0,142$ dans le régime asymétrique. Les probabilités AMS sont :

k	1	2	3	4
$P(FC_k)$	$1,42 \cdot 10^{-1}$	$6,06 \cdot 10^{-3}$	$1,88 \cdot 10^{-4}$	$4,46 \cdot 10^{-6}$
k	5	6	7	8
$P(FC_k)$	$1,11 \cdot 10^{-7}$	$1,11 \cdot 10^{-9}$	$1,36 \cdot 10^{-11}$	$1,87 \cdot 10^{-13}$

Les rapports $P(FC_k)/p_1^k$ décroissent fortement après $k = 1$. La courbe i.i.d. reste donc une référence utile, mais elle n'est pas un plancher de risque.

Mécanisme. Chaque cycle "réussi" (bid épuisé) laisse bien une mémoire Hawkes, mais il laisse aussi un ask partiellement consommé et reconstruit le bid. Dans le régime bid rare choisi pour atteindre des probabilités 10^{-7} – 10^{-10} , cet effet d'état domine : les cycles suivants deviennent plus difficiles que des essais Bernoulli indépendants de probabilité p_1 . Tout modèle qui réinitialise complètement les intensités et les files perd cette information conditionnelle.

Non-indépendance des cycles Hawkes quantifiée

La Proposition 6.2 fournit la grille de lecture correcte de la figure : si les cycles étaient indépendants, la courbe suivrait p_1^k ; sous Hawkes, les états hérités modifient les probabilités conditionnelles. Dans le régime bid rare du notebook, cette mémoire rend les flash crashes profonds moins probables que la référence i.i.d., ce qui confirme que le modèle Bernoulli ne peut pas remplacer l'AMS.

7 Importance Sampling par basculement exponentiel

7.1 Principe du changement de mesure

On remplace la loi P par une loi auxiliaire $\tilde{P}$ sous laquelle l'événement rare $\{\tau_b < \tau_a\}$ est plus fréquent, puis on corrige par $L = dP/d\tilde{P} : P(\tau_b < \tau_a) = \mathbb{E}_{\tilde{P}}[\mathbf{1}_{\tau_b < \tau_a} L]$.

Proposition 7.1 (Log-rapport de vraisemblance pour le basculement exponentiel). On tord les intensités d'annulation par $\theta > 0$: $\tilde{\lambda}_a^-(t) = e^{-\theta} \lambda_a^-(t)$, $\tilde{\lambda}_b^-(t) = e^{\theta} \lambda_b^-(t)$. Le log-rapport de vraisemblance sur l'intervalle $[0, \tau]$ est :

$$\log L = (e^{-\theta} - 1) I_a + (e^{\theta} - 1) I_b + \theta N_a - \theta N_b,$$

où $I_a = \int_0^{\tau} \lambda_a^-(t) dt$ est le *compensateur* (intégré exactement entre les événements), et N_a, N_b sont les comptages sous $\tilde{P}$.

Démonstration. Par la formule de Girsanov discrète pour les processus ponctuels (Jacod 1975) : $\log dP/d\tilde{P} = \int_0^{\tau} \log(\tilde{\lambda}_a^-/\lambda_a^-) dN_a + \int_0^{\tau} (\tilde{\lambda}_a^- - \lambda_a^-) dt + \text{terme bid.}$ On substitue $\tilde{\lambda}_a^- = e^{-\theta} \lambda_a^-$ et $\tilde{\lambda}_b^- = e^{\theta} \lambda_b^-$, ce qui donne les contributions événementielles $+\theta N_a - \theta N_b$ et les compensateurs $(e^{-\theta} - 1)I_a + (e^{\theta} - 1)I_b$. En combinant les deux côtés, on obtient le résultat. $\square$

7.2 Optimisation de θ^* et comparaison avec l'AMS

Le paramètre optimal θ^* minimise $CV^2(\theta) = \mathbb{E}_{\tilde{P}}[(\mathbf{1}_{\tau_b < \tau_a} L)^2]/P^2 - 1$. Il est calculé par balayage sur la grille utilisée dans le notebook.

Validation numérique

Objectif. On cherche $\theta^* = \arg \min_{\theta} CV^2(\theta)$, le paramètre de tilt exponentiel qui minimise la variance relative de l'estimateur IS. La démonstration poursuit deux buts : (1) quantifier le gain de variance effectivement obtenu par IS par rapport au MC naïf, et (2) comparer ce gain à celui déjà mesuré pour l'AMS sur le même problème.

Protocole.

- Paramètres de la file : même régime bid rare que la section flash crash, $\mu_a^- = 3,0$, $\mu_b^- = 1,2$, $q_{a,0} = 10$, $q_{b,0} = 12$.
- Balayage : grille positive de θ ; plus θ augmente, plus la loi auxiliaire favorise les annulations bid.
- Pour chaque θ : trajectoires sous $\tilde{P}_{\theta}$; calcul de $\hat{p}(\theta) = N^{-1} \sum L_i \mathbf{1}_{\tau_b < \tau_a}$ et du coefficient de variation empirique.
- Références : $\theta = 0$ correspond au MC naïf ; l'AMS bid-side fournit l'estimation de comparaison.




Figure 22 – Gauche : estimation de $\hat{P}(\tau_b < \tau_a)$ en fonction de θ , comparée aux références splitting AMS (tiret orange, 0,1387) et MC direct (pointillé bleu, 0,1390). Droite : coefficient de variation empirique de l'IS, avec $\theta^* \approx 0,30$ marqué en vert. Horiz. : θ ; vert. : probabilité / CV.

Lecture de la figure. Deux observations structurantes se dégagent des panneaux :

1. **Minimum net à $\theta^* \approx 0,30$** : pour les petits tilts ($0 \leq \theta \leq 0,30$), l'estimateur reste stable et converge vers les références AMS et MC direct. Le CV passe de 2,52 à 0 à 2,05, une réduction modeste mais significative.
2. **Effondrement rapide au-delà de θ^*** : dès $\theta = 0,60$, le CV bondit à 10 et l'estimateur commence à déraiser ; à $\theta = 1,80$, le CV atteint 109 et $\hat{p}$ s'effondre, signalant une dégénérescence des poids de vraisemblance.

Résultats quantitatifs. La grille du rerun ($N = 30\,000$ trajectoires par point) donne un minimum empirique clairement identifiable à $\theta^* \approx 0,30$:

θ	$\hat{p}_{IS}$	CV
0,00	0,1363	2,517
0,30	0,1388	2,052
0,60	0,1331	10,278
0,90	0,1393	30,471
1,20	0,0521	63,355
1,50	0,0162	85,376
1,80	0,0058	109,121
2,10	≈ 0	28,841

Les références indépendantes sont cohérentes : le splitting AMS donne 0,1387 et le MC direct donne 0,1390 (27 802/200 000 succès). En revanche, les grands tilts produisent des poids instables qui font diverger le CV ; ils ne doivent pas être interprétés comme de meilleurs estimateurs. La chute du CV observée à $\theta = 2,10$ est trompeuse : elle provient du fait que presque aucune trajectoire n'atteint $\tau_b < \tau_a$ sous ce tilt trop agressif, faisant tendre $\hat{p}$ vers zéro.

Pourquoi l'IS est moins efficace que l'AMS. Le basculement exponentiel modifie *uniformément* les intensités de décrémentation : il rend globalement plus probable l'épuisement bid, mais sans cibler les trajectoires qui progressent niveau par niveau vers zéro. L'AMS, en revanche, exploite explicitement la structure de niveau de l'événement rare : chaque étape de splitting guide les particules vers des états de plus en plus proches de l'épuisement. C'est cette exploitation de la géométrie du problème qui explique sa meilleure stabilité dans ce notebook.

IS optimal ($\theta^* \approx 0,30$) comparable à l'AMS sur ce problème

Un tilt modéré ($\theta^* \approx 0,30$) réduit le CV de 2,52 à 2,05 (−19 % par trajectoire). La comparaison directe CLT à N fixé (§ 7.3) montre que, au même N , l'IS avec θ^* atteint même une efficacité supérieure à l'AMS ($RE = 0,57 < 1$, voir ci-après). Toutefois, les grands tilts ($\theta > 0,60$) dégénèrent rapidement : l'IS reste donc utile comme contrôle de vraisemblance et comme estimateur alternatif au voisinage de θ^* .

7.3 Comparaison directe CLT : AMS vs IS

Pour quantifier la question « quel estimateur est le plus précis à N fixé ? », on effectue $R = 50$ répliques indépendantes de chaque méthode avec $N = 500$ trajectoires/particules, puis on mesure l'écart-type empirique des estimées $\hat{P}$ et la largeur des IC 95 % en fonction de N .




Figure 23 — Comparaison CLT : AMS (orange) vs IS $\theta = 0,30$ (violet). **Gauche** : histogrammes de $\hat{P}$ sur $R = 50$ répliques à $N = 500$; le pic plus étroit de l'IS traduit une variance plus faible. **Droite** : largeur d'IC 95 % en fonction de N ; les deux courbes décroissent en $1/\sqrt{N}$ (ligne pointillée de référence). *Horiz.* : $\hat{P}$; N ; *vert.* : nombre de répliques ; largeur IC.

Résultats quantitatifs. Sur les $R = 50$ répliques à $N = 500$:

Estimateur	$\hat{\sigma}(\hat{P})$	RE
Splitting AMS	0,01712	1,00 (référence)
IS ($\theta^* = 0,30$)	0,01289	0,57

où $RE = (\sigma_{IS}/\sigma_{AMS})^2 = 0,57 < 1$: à nombre de trajectoires/particules identique, l'IS avec $\theta^* = 0,30$ requiert environ 43 % moins de réplifications que l'AMS pour atteindre la même précision sur ce problème.

Ce résultat complète la conclusion du § 7 : le tilt exponentiel modéré ne peut pas exploiter la géométrie par niveaux de l'événement rare (contrairement au splitting), mais il tilte suffisamment les trajectoires vers la zone rare pour surpasser l'AMS à N modéré. L'AMS reprend l'avantage pour les événements très profonds ($k \geq 5$) où sa structure par niveaux est indispensable.

Troisième partie

Calibration par maximum de vraisemblance et confrontation aux données de marché

Les deux premières parties ont construit et exploité le modèle sur des paramètres synthétiques choisis pour leurs propriétés analytiques. La question naturelle est : *ce modèle peut-il être rendu opérationnel sur des données de marché réelles ?* Cela exige deux étapes : d'abord identifier les paramètres $(\mu_a^-, \mu_b^-, \alpha, \beta)$ depuis une séquence d'événements observés, via le maximum de vraisemblance ; ensuite vérifier que les estimées obtenues permettent de retrouver, via l'AMS, des probabilités d'événements rares cohérentes avec l'histoire observée. Nous appliquons cette démarche sur données simulées (validation croisée) puis sur les données Bitcoin du 12 mars 2020, épisode de liquidations en cascade connu sous le nom de *Black Thursday*.

8 Calibration par maximum de vraisemblance

8.1 Log-vraisemblance du Hawkes bivarié à couplage croisé

On calibre le modèle de la section 3 : excitation propre par les décréments $(+\alpha)$, inhibition propre par les incréments $(-\alpha)$, excitation croisée par *tous* les événements de la file opposée $(+\alpha)$. Pour la calibration depuis des séquences de décréments $\mathcal{D}_a, \mathcal{D}_b$ uniquement (les incréments à taux constant λ^+ sont absorbés dans le fond μ_a, μ_b), le modèle réduit s'écrit : $\lambda_a^-(t) = \mu_a + \alpha(R_a(t) + R_b(t))$ et $\lambda_b^-(t) = \mu_b + \alpha(R_b(t) + R_a(t))$.

Proposition 8.1 (Log-vraisemblance en $O(n)$, couplage croisé excitateur). Soit $\mathcal{D}_a, \mathcal{D}_b$ les décréments ask/bid sur $[0, T]$. Avec les récurrences $R_a(t_i) = e^{-\beta(t_i - t_{i-1})} R_a(t_{i-1}) + \mathbf{1}_{t_i \in \mathcal{D}_a}$ (et R_b

symétriquement), la log-vraisemblance est :

$$\ell(\mu_a, \mu_b, \alpha, \beta) = \sum_{t \in \mathcal{D}_a} \log(\mu_a + \alpha(R_a(t) + R_b(t))) + \sum_{t \in \mathcal{D}_b} \log(\mu_b + \alpha(R_b(t) + R_a(t))) \\ - (\mu_a + \mu_b)T - \frac{2\alpha}{\beta}(S_a + S_b),$$

où $S_a = \sum_{s \in \mathcal{D}_a} (1 - e^{-\beta(T-s)})$ et $S_b = \sum_{s \in \mathcal{D}_b} (1 - e^{-\beta(T-s)})$.

Justification du compensateur. Pour le modèle à couplage croisé excitateur : $\int_0^T \lambda_a^-(t) dt = \mu_a T + (\alpha/\beta)S_a + (\alpha/\beta)S_b$ et $\int_0^T \lambda_b^-(t) dt = \mu_b T + (\alpha/\beta)S_b + (\alpha/\beta)S_a$. La somme totale des compensateurs vaut donc : $-(\mu_a + \mu_b)T - (2\alpha/\beta)(S_a + S_b)$. Contrairement au cas inhibitoire, les termes croisés s'additionnent au lieu de s'annuler. $\square$

8.2 Résultats numériques : validation synthétique

	μ_a^-	μ_b^-	α	β
Vraies valeurs	3,0	1,5	0,35	1,0
Estimées par MLE	3,0130	1,5033	0,3703	1,1540

Table 3 – Calibration MLE sur 150 cycles synthétiques ($T = 228,2$, $|\mathcal{D}_a| = 1601$, $|\mathcal{D}_b| = 1255$). La contrainte de stabilité du modèle réduit est $2\alpha < \beta$, d'où le choix $\alpha = 0,35$, $\beta = 1,0$.




Figure 24 – Calibration MLE du Hawkes bivarié à couplage croisé excitateur. Gauche : taux de décrémentation ask/bid empiriques (bleu/orange) et valeurs calibrées (tirets). Droite : profil de log-vraisemblance en μ_a^- . Horiz. : temps ; μ_a^- ; vert. : taux ; log-lik.

La validation synthétique sert de contrôle de cohérence : les paramètres de fond μ_a^-, μ_b^- doivent être retrouvés au bon ordre de grandeur, tandis que (α, β) peuvent être plus bruités sur un échantillon court car ils sont fortement corrélés dans la vraisemblance. Le notebook impose maintenant la condition $2\alpha < \beta$, cohérente avec le compensateur du modèle réduit.

9 Application aux données réelles : Bitcoin Black Thursday

9.1 Contexte et mécanisme microstructural

Le 12 mars 2020, le Bitcoin a perdu **41 %** de sa valeur en une seule journée (7 900 \$ → 3 800 \$). Le mécanisme est directement celui de notre modèle :

1. Liquidations automatiques en cascade : chaque baisse de prix entraîne de nouvelles liquidations de longs leveragés (auto-excitation côté bid).
 2. Couplage croisé excitateur : une liquidation bid augmente λ_b^- (auto-excitation) et également λ_a^- via le couplage croisé (section 3), mais l'auto-excitation propre de λ_b^- domine, alimentant la cascade bid.
 3. Market makers absents : la volatilité implicite explosive les fait se retirer, amplifiant la spirale.
- C'est précisément la cascade $\{\tau_b^{(1)} < \tau_a, \dots, \tau_b^{(k)} < \tau_a\}$ que notre modèle quantifie.

9.2 Données : API Binance 1h

On utilise les bougies BTC/USDT 1h de l'API publique Binance (2020-01-01 à 2020-03-14, sans clé). Une bougie négative est interprétée comme un décrément bid ($\tau_b < \tau_a$), une bougie positive comme un décrément ask. Les nombres exacts d'observations et de bougies pré-crise sont ceux du rerun : 1746 bougies téléchargées, dont 1696 dans la fenêtre pré-crise utilisée pour la calibration.

9.3 Calibration et estimation AMS




Figure 25 — Gauche : cours BTC/USDT 1h (fenêtre de crise en rouge). Centre : taux de décrément ask/bid pré-crise et valeurs calibrées. Droite : $P(k$ bougies négatives consécutives) par AMS (bleu) vs modèle indépendant (orange). Horiz. : date ; prix USD ; profondeur k ; vert. : prix ; taux ; probabilité (log).

Black Thursday : événement de cascade bid rare sous le régime pré-crise

Le rerun calibre $(\hat{\mu}_a, \hat{\mu}_b, \hat{\alpha}, \hat{\beta}) = (0,5117, 0,4836, 0,0000, 3,7754)$ en events/heure sur la fenêtre pré-crise. Le maximum de 5 bougies négatives consécutives observé dans la fenêtre de crise a une probabilité AMS $8,47 \cdot 10^{-6}$, soit environ 1/118 112, sous ce régime calibré. Le régime pré-crise est donc quasi-Poisson ($\hat{\alpha} \simeq 0$), tandis que Black Thursday correspond à une cascade bid rare.

10 Tentative de modélisation du squeeze GameStop

Données intraday insuffisantes — modélisation abandonnée

Nous avons tenté d'appliquer la même procédure au squeeze de GameStop de janvier 2021 (cours $\times 30$ en moins d'une semaine). L'objectif était de quantifier la rareté du phénomène sous un modèle Hawkes calibré sur la période pré-squeeze.

Aspect	GME (données journalières)	BTC Black Thursday (1h Binance)
Résolution	1 pt/jour ($\times 70$ obs.)	24 pts/jour ($\times 1\,696$ obs.)
Unité de β	Sans unité physique (événements/jour)	events/heure
Mécanisme	Coordination Reddit (exogène)	Liquidations en cascade (endogène)
Calibration MLE	Instable ($\hat{\alpha} \rightarrow 0$ ou $\rightarrow \beta^-$)	Stable ($\hat{\alpha} = 0$ attendu)

Table 4 – Comparaison des deux études de cas. Les données journalières GME sont insuffisantes pour calibrer un Hawkes bivarié.

Causes de l'échec. (1) 70 observations : vraisemblance trop plate pour identifier α et β séparément. (2) Le mécanisme est exogène (coordination Reddit, non endogène au carnet). (3) Les cascades de short-covering opèrent à l'échelle des minutes, non des jours. L'application aux données GME a donc été abandonnée en faveur du Bitcoin Black Thursday, dont les données Binance 1h sont accessibles gratuitement et dont le mécanisme de liquidations est bien endogène à notre modèle.

Conclusion

Bilan

Ce projet a suivi une progression délibérément cumulative : chaque couche de modélisation a été motivée par les limites observées de la couche précédente, et chaque méthode numérique a été choisie pour répondre à une difficulté concrète.

Construction du modèle. La trajectoire du modèle illustre comment l'introduction de mémoire modifie profondément la dynamique d'épuisement. Le temps moyen d'épuisement passe de 12,4 (Poisson indépendant, proche de la prédiction brownienne 12,5) à 5,9 pour le Hawkes couplé : l'auto-excitation et le couplage croisé exciteur accélèrent le vidage d'un côté en alimentant aussi l'autre, créant une asymétrie structurelle même lorsque les paramètres de fond sont symétriques. La loi inverse-gaussienne, dérivée par arrêt optionnel, fournit une approximation analytique de la distribution de τ validée à

$+0,18\%$ sur la moyenne et $-0,11\%$ sur la variance (test KS : $p = 0,1734$). Au niveau du prix, l'asymétrie μ_a^-/μ_b^- se traduit directement en dérive du mid-price, conformément à la Proposition 4.1 : le modèle est donc *identifiable* depuis l'observation des trajectoires de prix.

Estimation des événements rares. Le Monte-Carlo naïf devient inutilisable lorsque la probabilité de l'événement cible devient très faible : son coefficient de variation diverge en $1/\sqrt{p}$, ce qui impose un coût prohibitif. Le splitting AMS résout ce problème en décomposant l'événement rare en paliers successifs. L'importance sampling par basculement exponentiel fournit un contrôle indépendant : à N fixé, l'IS avec $\theta^* = 0,30$ est même plus efficace que l'AMS (RE = 0,57), mais sans exploiter la structure par niveaux, il perd cet avantage pour les flash crashes profonds. Le résultat central de cette partie est la non-indépendance des cycles Hawkes : chaque épuisement bid transporte un état complet vers le cycle suivant (intensités, volume ask restant, bid reconstruit). Dans le régime bid rare corrigé, cette dépendance rend les cascades profondes moins probables que la référence i.i.d. p_1^k ; l'important est donc de ne pas remplacer l'AMS par une hypothèse de cycles indépendants.

Calibration et validation. La version à couplage croisé exciteur de la log-vraisemblance (intégrant les termes de type $R_a + R_b$) permet d'identifier les paramètres du modèle réduit sous la contrainte de stabilité $2\alpha < \beta$. Les paramètres de fond μ sont les plus robustes ; (α, β) restent plus corrélés sur des séquences courtes. Sur les données Bitcoin du 12 mars 2020, la calibration pré-crise et l'AMS évaluent directement la rareté des cascades de bougies négatives, interprétées comme épuisements bid successifs.

Perspectives

Plusieurs directions naturelles prolongent ce travail. **Sur le plan des données**, les données tick-by-tick (TARDIS, Kaiko) permettraient de calibrer le modèle à une résolution temporelle bien plus fine que les données horaires utilisées ici, et d'estimer α et β avec une précision accrue. **Sur le plan du modèle**, l'extension à $L > 2$ niveaux de prix est directement implémentable en ajoutant des files $q_{a,k}$, $q_{b,k}$ supplémentaires avec une structure d'excitation similaire ; un noyau de Hawkes à inhibition stochastique (variance dans le saut α) permettrait de mieux capturer les régimes transitoires observés autour des crises. **Sur le plan statistique**, un test de Mann-Whitney formel sur les distributions conditionnelles de q_2 validerait rigoureusement la distinction entre côté ask et côté bid ; et relier $\mathbb{P}(\tau_a < \tau_b)$ calibré sur le passé à une surface de volatilité implicite ouvrirait une application directe à la couverture d'options sur carnet d'ordres.