




MODÉLISATION STOCHASTIQUE D'UN CARNET D'ORDRES

Simulation, événements rares et calibration

QU'EST-CE QU'UN CARNET D'ORDRES ?



Source : MODAL Queue Reactive (Lehalle, 2025-26).

Un **carnet d'ordres à cours limité** centralise toutes les intentions d'achat et de vente en attente pour un actif donné.

Côté acheteur (**bid**, q_b) : ordres d'achat à prix $\leq p_0$.

Côté vendeur (**ask**, q_a) : ordres de vente à prix $\geq p_0$.

- **Première limite** : la meilleure offre disponible de chaque côté (Q_{-1} et Q_1).
- **Spread** : écart entre la première limite ask et la première limite bid.
- **Transaction** : un ordre de marché consomme la première limite du côté opposé — si elle s'épuise, le **prix saute**.

LE FIL CONDUCTEUR



À chaque instant, le carnet contient un volume côté acheteur (q_b , le *bid*) et côté vendeur (q_a , l'*ask*). Dans le modèle Queue Reactive, le prix change lorsque la meilleure limite d'un des deux côtés est consommée.

La question centrale se ramène donc à deux temps d'atteinte :

$$\tau_a = \inf\{t : q_{a,1}(t) = 0\}, \quad \tau_b = \inf\{t : q_{b,1}(t) = 0\}.$$

Quel côté s'épuise en premier, à quel horizon, et avec quelle probabilité ?

Plan de l'étude :

- I. **Modéliser** la logique du Carnet d'Ordres — du Poisson au Hawkes couplé.
- II. **Optimiser** les ressources computationnelles et **Simuler** quelques scénarios extrêmes.
- III. **Calibrer** sur un vrai crash du marché.

1

CONSTRUIRE LE MODÈLE



POINT DE DÉPART : MODÈLE POISSON INDÉPENDANT



Chaque file est d'abord modélisée par


$$\begin{aligned}q(t) &= q_0 + N_t^+ - N_t^-, \\ \mu &= \lambda^+ - \lambda^- = -0,8 < 0, \\ \sigma^2 &= \lambda^+ + \lambda^- = 3.2.\end{aligned}$$

La limite diffusive donne un temps d'atteinte de 0 de loi **inverse-gaussienne** :

$$\tau \sim \text{IG}\left(\frac{q_0}{|\mu|}, \frac{q_0^2}{\sigma^2}\right), \quad \mathbb{E}[\tau] = 12,5.$$

Rôle dans le projet : étalon analytique pour valider la simulation.

- MC : $\mathbb{E}[\tau] = 12,52$ (+0,14%).
- Test KS : $p = 0,097$; IG non rejetée.



Densité IG théorique vs histogramme simulé.




Par conditionnement sur τ_a :

$$\mathbb{P}(\tau_a < \tau_b) = \int_0^\infty f_{\tau_a}(t) (1 - F_{\tau_b}(t)) dt.$$

La quadrature de Gauss–Legendre donne une référence déterministe pour comparer le Monte-Carlo.

Vérification numérique : l'écart maximal avec Monte-Carlo est 0,049, du même ordre que l'erreur statistique MC ($\approx 0,044$). La différence observée est donc compatible avec la variabilité de simulation.



MC (g.) vs quadrature IG (c.) vs écart (d.). Sur la diagonale

$$\hat{p} \approx \frac{1}{2}.$$

PROCESSUS DE HAWKES : MÉMOIRE ET TRONCATURE



L'intensité d'annulation intègre la mémoire des événements passés :

$$\lambda^-(t) = \mu^- + \alpha \sum_{s \in \mathcal{N}^-, s < t} e^{-\beta(t-s)} - \alpha \sum_{s \in \mathcal{N}^+, s < t} e^{-\beta(t-s)}.$$


Chaque événement imprime une impulsion sur λ^- , positive pour $\mathcal{N}^-$ et négative pour $\mathcal{N}^+$, puis cette contribution s'amortit exponentiellement.

Sans troncature, la théorie stationnaire donne $\bar{\lambda}_{\infty}^- = 2,80$.

Simulation : la moyenne mesurée est 2,96, soit +5,9%.

Lecture de l'écart

La théorie est calculée sans troncature, tandis que la simulation impose un plancher $\lambda^- \geq 0$. Les inhibitions trop fortes sont donc coupées, ce qui explique la surestimation observée de $\bar{\lambda}^-$.



Moyennes temporelles de λ^- ; ligne rouge = 2,80. La masse est décalée à droite.

HAWKES COUPLÉ : EFFET DU COUPLAGE BID/ASK



Chaque côté conserve une mémoire décroissante :
auto-excitation par les décréments, **inhibition par les**
incréments, et excitation croisée par l'autre file :

$$\lambda_a^-(t) = \mu_a^- + \alpha \sum_{s \in \mathcal{D}_a} e^{-\beta(t-s)} - \alpha \sum_{s \in \mathcal{A}_a} e^{-\beta(t-s)} + \alpha \sum_{s \in \mathcal{C}_b} e^{-\beta(t-s)}$$


$\mathcal{D}_a, \mathcal{A}_a$: décréments / incréments ask ; $\mathcal{C}_b = \mathcal{D}_b \cup \mathcal{A}_b$: tous les événements bid.

Effet mesuré au point $q_0 = (10, 10)$:


$$\mathbb{E}[\min(\tau_a, \tau_b)] : 8,3 \text{ (Poisson)} \rightarrow 5,8 \text{ (couplé)}, \quad -30\%.$$

Le couplage accélère l'épuisement conjoint des deux côtés
: il introduit un mécanisme de cascade absent du cas
Poisson indépendant.

Temps moyen d'atteinte de 0 — Hawkes couplé



Probabilité que l'ask atteigne 0 avant le bid — Hawkes couplé



Hawkes couplé : temps moyen (g.) et probabilité ask
avant bid (d.).


QUATRE RÉGIMES : EFFET PROGRESSIF DE LA MÉMOIRE

PARTIE I



Modèle	Moy.	Méd.
Poisson indiv.	12,4	10,6
Min de 2 Poisson	8,6	7,7
Hawkes indiv.	8,8	6,9
Hawkes couplé	5,9	5,1

Lecture : l'ajout de mémoire accélère l'épuisement et renforce la queue gauche de la distribution des temps d'arrêt.



Trois effets se cumulent : (1) minimum de deux files ; (2) auto-excitation ; (3) couplage bid/ask. Le facteur global est proche de 2,1.

DEUXIÈME LIMITE : RECONSTRUIRE LE CARNET



Deux lois pour la deuxième limite. Le niveau 2 évolue avant le saut :

$$\lambda_{2,0}^+(t) = \mu_2^+,$$

$$\lambda_{2,c}^+(t) = \mu_2^+ + \sum_{T_i^\downarrow < t} a e^{-b(t-T_i^\downarrow)}.$$

Sans couplage : référence autonome.


Avec couplage : les décréments du niveau 1 rechargent q_2 .

Quand l'ask s'épuise, le volume de niveau 2 devient la nouvelle meilleure limite :


$$q_{a,1} \leftarrow q_{a,2}(\tau_a), \quad p_0 \uparrow \frac{\delta^P}{2}.$$

Donc : la **loi conditionnelle** de $q_2(\tau)$ dépend du choix de couplage pour λ_2^+ .

Sans couplage : $\lambda_2^+ = \mu_2^+$, moyennes $\approx 8,0$



Avec couplage : λ_2^+ excitée par le niveau 1, moyennes $\approx 10-11$



PASSAGE AU PRIX : DÉRIVE INDUITE PAR L'ASYMÉTRIE




Modèle à 4 limites : à chaque épuisement, le prix saute de $\pm\delta^p/2$, et les intensités Hawkes sont **transportées** d'un cycle à l'autre.

$$\Delta p_0 = \frac{\delta^p}{2}(2p - 1), \quad p = \mathbb{P}(\tau_a < \tau_b).$$


Lecture

- $p = \frac{1}{2}$: prix martingale.
- $p > \frac{1}{2}$: dérive haussière.
- $p < \frac{1}{2}$: dérive baissière.

Le cas symétrique sert de référence ; l'asymétrie $\mu_a^- \neq \mu_b^-$ crée une tendance directionnelle.



Cas symétrique : pas de tendance (martingale).



Cas asymétrique : tendance haussière nette.

2

SIMULER LES RÉGIMES EXTRÊMES



RÉDUIRE LE COÛT DE SIMULATION



Avant les cascades rares. On étudie d'abord un cas de contrôle, avec probabilité $p \simeq 0,14$, où le Monte-Carlo direct reste disponible comme référence.

Objectif. Comparer MC direct et AMS à précision comparable. Le MC direct relance chaque trajectoire depuis zéro ; le splitting AMS **recycle** celles qui ont déjà atteint des paliers intermédiaires.

Résultat attendu : **même précision, moins de simulations.**

Benchmark contrôlé

- MC direct : $N = 10^5$.
- Splitting AMS : $N = 3 \cdot 10^4$.
- Même loi de $Q_2(\tau)$: forme et support conservés.

Une fois validé sur $p \simeq 0,14$, le même outil est utilisé pour les cascades vraiment rares.


SPLITTING AMS : RECYCLER LES TRAJECTOIRES

PARTIE II



Principe. Plutôt que de relancer N trajectoires depuis zéro, on conserve celles qui ont déjà atteint le palier précédent : elles sont rééchantillonnées et seul le tronçon restant est simulé.

Sur le benchmark modéré, cela mesure le gain de budget. Pour les flash crashes, cela revient ensuite à décomposer une probabilité infime en produit de probabilités conditionnelles, en transportant l'état **Hawkes complet**.



Écart-type de $\hat{P}_{AMS}$ sur le benchmark $p \simeq 0,14$: la droite log-log valide la CLT.

Validation : pente log-log $\approx -0,5$; CV réduit d'un facteur 7 entre $N = 50$ et $N = 3200$.


LOI DE Q_2 : CONTRÔLE PAR MONTE-CARLO DIRECT



La loi de $Q_{a,2}(\tau)$ conditionne l'état initial du cycle suivant. Pour vérifier que le splitting ne déforme pas cette loi, on compare deux estimateurs.

- **MC direct** ($N=10^5$) : référence brute — la plupart des trajectoires ne conditionnent pas sur $\tau_a < \tau_b$.
- **Splitting AMS** ($N=3 \cdot 10^4$) : seules les trajectoires recyclées contribuent.

Résultat : même distribution avec **3**× moins de calcul. Validation empirique que le recyclage ne déforme pas la loi conditionnelle.



Loi de $Q_{a,2}(\tau_a)$: Monte-Carlo direct ($N=10^5$, g.) vs splitting AMS ($N=3 \cdot 10^4$, d.). Même forme, même support.

FLASH CRASH DE PROFONDEUR k




On appelle flash crash de profondeur k une série de k épuisements *bid* avant qu'un épuisement ask ne casse la séquence :

$$FC_k = \{\tau_b^{(1)} < \tau_a, \dots, \tau_b^{(k)} < \tau_a\}.$$

Les cycles ne sont pas i.i.d. : après chaque saut, les volumes reconstruits et les intensités Hawkes sont transportés.

$$\mathbb{P}(FC_k) = \prod_{i=1}^k c_i,$$
$$c_i = \mathbb{P}(\tau_b^{(i)} < \tau_a \mid FC_{i-1}).$$

Lecture : au-delà de $k = 3$, l'événement devient invisible au MC direct ; le splitting AMS permet de poursuivre l'estimation.



Ordres de grandeur. Régime bid rare : $\mu_a^- = 3,0$, $\mu_b^- = 1,2$,
 $q_{a,0} = 10$, $q_{b,0} = 12$.

$$\mathbb{P}(FC_1) \simeq 1,4 \cdot 10^{-1} ; \mathbb{P}(FC_5) \simeq 1,1 \cdot 10^{-7} ; \mathbb{P}(FC_8) \simeq 1,9 \cdot 10^{-13}.$$


SPLITTING EN DEUX PHASES



Idée. Les premiers paliers de l'AMS ne dépendent pas de la cible finale et sont **réutilisables**. On les calcule une fois hors-ligne, on stocke $\hat{\pi}_{k^*}$, puis on ne simule que les derniers paliers en ligne :

$$\hat{P}(\tau_s < \tau_{\bar{s}}) = \underbrace{\prod_{j=Q_0-1}^{k^*+1} \hat{p}_j}_{P_{\text{off}}} \times \hat{P}(\tau_s < \tau_{\bar{s}} \mid q_{s,1} \leq k^*)$$

Gain de calcul : splitting complet
= 7,69 s par requête ; avec deux phases :
7,69 s une fois hors-ligne, puis 0,67 s par
requête en ligne ($\times 11$ plus rapide).
Moyennes 12,90 vs 12,91.




Loi de $Q_{a,2}$: splitting complet (g.) vs bootstrap depuis $\hat{\pi}_{k^*=5}$ (d.).

Moyennes 12,90 vs 12,91.



Principe. Au lieu de sélectionner les trajectoires par niveaux, on **modifie la loi simulée** pour rendre l'événement plus fréquent, puis on corrige par un poids de vraisemblance. Le paramètre θ règle l'intensité de la déformation.

- $\theta^* \approx 0,30$: meilleur réglage observé.
- $\theta > 0,6$: les poids deviennent instables, avec un CV qui dépasse 100.





Probabilité estimée (g.) et coefficient de variation (d.) en fonction de θ ; minimum net en $\theta^* \approx 0,30$.

COMPARAISON AMS / IS À N FIXÉ



§19 — IC splitting vs IS | $\mu_a^- = 3.0$, $\mu_b^- = 1.2$ | IS plus efficace (RE=0.57)



À gauche : dispersion de $\hat{P}$ (le pic plus étroit de l'IS = variance moindre). À droite : largeur d'IC, en $1/\sqrt{N}$ pour les deux.


	RE
AMS	1,00
IS (θ^*)	0,57

À N égal, l'IS bien réglé donne ici une variance plus faible que l'AMS (−43%). Cette conclusion vaut pour l'événement modéré testé. Pour des cascades plus profondes, la structure par niveaux de l'AMS devient l'avantage principal.

3

CONFRONTER AU RÉEL





À gauche : vraies valeurs vs estimées MLE. À droite : intensité $\lambda_a^-(t)$ reconstruite (tirets) vs vraie (bleu).


Validation synthétique (150 cycles). Les intensités de fond μ sont retrouvées à moins de 1% près. Les paramètres (α, β) sont moins stables, car ils sont corrélés dans la vraisemblance sur un échantillon court.

	μ_a^-	μ_b^-	α	β
Vrai	3,0	1,5	0,35	1,0
MLE	3,01	1,50	0,37	1,15
Err.	< 1%	< 1%	6%	15%

BITCOIN BLACK THURSDAY : DONNÉES 1H



§21 — BTC Black Thursday : l'événement observé ($k=5$) était rare sous le régime pré-crise (calibré sur 1696 obs. | binance-1h (1746 bougies))



12 mars 2020 : BTC perd environ 41% en une journée. Données Binance en bougies 1h ; calibration sur les 1696 observations pré-crise.

Résultat principal : le régime pré-crise est calibré avec $\hat{\alpha} \approx 0$, donc presque Poisson. Sous ce régime, la séquence observée de 5 bougies négatives consécutives a une probabilité AMS de $8,5 \cdot 10^{-6}$ ($\approx 1/118\,000$).



Une tentative non retenue

La même procédure a été testée sur le squeeze GME de janvier 2021, mais les hypothèses du modèle ne sont pas adaptées :

	GME (journalier)	BTC (1h)
Résolution	70 obs.	1696 obs.
Mécanisme	Coordination Reddit (exogène)	Liquidations (endogène)
Calibration	Instable	Stable

Deux limites dominant : (1) 70 points donnent une vraisemblance trop plate ; (2) surtout, le moteur de GME est **hors du carnet**. Le modèle décrit des cascades endogènes de liquidité, pas une coordination externe.

CONCLUSION



- I. La mémoire Hawkes réduit les temps d'épuisement et modifie la loi complète via le mécanisme d'auto-excitation.
- II. AMS sert d'abord à économiser le budget sur un benchmark modéré, puis à traiter les cascades rares ; IS sert de comparaison indépendante quand les poids restent stables.
- III. Sur Black Thursday, le régime pré-crise calibré est quasi-Poisson ; la séquence observée reste rare dans ce régime, ce qui illustre le risque de sous-estimer une crise avec une calibration calme.

Perspectives

- Données tick-by-tick (TARDIS/Kaiko) pour mieux séparer α, β .
- Extension à $L > 2$ niveaux.
- Résilience du carnet : réapparition possible des limites consommées.

