

Simulations de Modèles de carnets d'ordres

Charles-Albert Lehalle

MODAL 2025-2026 v1.3

1 Microstructure des marchés financiers

1.1 Liquidité et carnets d'ordres à cours limité

Une des caractéristiques les plus importantes du système financier est la *liquidité* qu'il fournit à l'économie réelle : pour qu'un acteur économique qui désire épargner, désépargner, se couvrir contre un risque, ou au contraire s'exposer à un facteur de risque, puisse le faire à moindre coût, il est nécessaire qu'il trouve facilement un acheteur ou un vendeur du véhicule financier en question.

Un exemple simple est l'achat puis la vente d'une action : lorsqu'une entreprise désire lever des capitaux, elle va le faire en émettant des actions¹. Elle a donc besoin d'acheteurs de ses actions : ce sont des particuliers ou des entreprises qui vont les acquérir. Ces actions sont liquides au moment de leur émission si, il n'est pas nécessaire de baisser artificiellement leur prix pour attirer des acheteurs. Cela peut se produire si les acheteurs ne sont pas présents aux enchères au moment de l'émission. Cet effet est particulièrement important sur le marché secondaire : une fois que les actions sont émises, elles vont s'échanger au gré des anticipations et des besoins des différents participants de marché. Il y a plus de 8,000 actions sur les marchés américains, et presque autant en Europe. Il n'est pas toujours facile pour les participants d'être présent au bon moment, sur la bonne enchère. Elles sont liquides, c'est-à-dire que leur prix ne doit pas être artificiellement baissé ou monté au gré de la venue de vendeurs et d'acheteurs, si les parties prenantes sont bien présentes pendant les enchères.

Depuis le début du siècle, ces enchères ont lieu dans les serveurs des bourses (New York Stock Exchange, NASDAQ, Euronext Bourse de Paris, London Stock Exchange group, etc), qui reçoivent des ordres d'achat et de vente. Le mécanisme est simple :

1. l'acheteur ou le vendeur envoie un *ordre* au serveur, qui est décrit par un prix, une quantité et une direction (achat ou vente),
2. le serveur compare le prix aux ordres déjà stockés dans son *carnet d'ordres* :
 - si c'est un ordre vendeur (respectivement acheteur) et qu'il y a un acheteur (resp. vendeur) présent à un prix au moins aussi élevé (resp. bas), alors une transaction est émise et l'ordre stocké est retiré du carnet d'ordres ;
 - sinon, le nouvel ordre est stocké à son tour dans le carnet d'ordres.

Le carnet d'ordre est donc constitué de *files d'attentes* (il y a une file d'attente pour chaque prix possible²) qui sont signées (vendeuse ou acheteuse) et listent, dans leur rang d'arrivée, les ordres attendant une contrepartie à ce prix. La figure 1 est illustrative. Pour plus de détails, cf [LL18].

Chacune de ces file d'attente est soumise à plusieurs événements :

- un des ordres qui la constitue peut être *annulé*, elle diminue alors d'une quantité arbitraire ;

¹ce qui est moins contraignant qu'en émettant de la dette car les acheteurs de ces actions acceptent de partager le risque d'échec avec l'entreprise.

²les prix sont discrétisés le long de multiple d'un *pas de cotation* fixé dans les règles de la bourse.




Figure 1: Un carnet d'ordres stylisé : les files d'attente d'ordres à l'achat sont en vert et leur taille est signée positivement, alors que les files d'attente d'ordres à la vente sont en rouge et leur taille est signée négativement.

- un nouvel ordre peut y être *ajouté*, elle augmente alors ;
- si il s'agit d'une des deux *premières limites*, une *transaction* peut avoir lieu qui diminue alors la quantité présente sur cette file d'attente tout en “généralisant” une transaction.

1.2 Modèles Queue Reactive

1.2.1 Principe du Modèle Queue Reactive

Plusieurs modèles ont été proposés pour reproduire la dynamique des carnets d'ordres, le plus complet est appelé *Queue Reactive Model* [HLR15]; il repose sur le principe que les trois types d'événements $\{L, C, T\}$ (pour “*Limit, Cancel, Trade*”) qui peuvent modifier la taille d'une file d'attente surviennent suivant des processus de Poisson $\mathcal{P}^+, \mathcal{P}^-, \mathcal{P}^T$ dont les intensités $\lambda^+, \lambda^-, \lambda^T$ sont des fonctions de l'état du carnet d'ordres.

Indiquons les files d'attente côté bid (achat) par des entiers négatifs, et les files d'attente côté ask (vente) par des entiers positifs. Ainsi Q_{-1} est la quantité de la première limite acheteuse, Q_{-2} la deuxième limite acheteuse, Q_1 est la quantité de la première limite vendeuse, Q_2 la deuxième limite vendeuse, etc.

Hypothèse 1 (Modèle Queue Reactive) Les trois événements *Limit, Cancel, Trade* qui touchent la limite i suivent des processus de Poisson d'intensité qui dépend de la forme du carnet d'ordres $(Q_i)_{i \in \mathbb{Z}}$.

1.2.2 Objectif du MODAL

Le sujet du MODAL est de simuler la plus précisément possible les processus $(Q_i(t))_{i \in \mathbb{Z}}$. De ce point de vue il n'y a pas de différence entre une transaction et une annulation : dans les deux cas la quantité diminue.

Hypothèse 2 (Simplification) On considère que tous les processus ponctuels correspondent à un ajout ou une soustraction d'une unité (i.e. une action).

1.2.3 Première modélisation: premières limites seulement, indépendantes

Pour commencer, on va noter $\lambda^\oplus$ l'intensité du processus de Poisson d'ajout de liquidité et $\lambda^\ominus$ l'intensité du processus de diminution de liquidité.




Figure 2: Example of simulation (Question 1.2.3.0).




Figure 3: Comparison of distributions of hitting times (Question 1.2.3.3).

On va les considérer comme constantes. Par exemple $\lambda^{\oplus} = 1.2$ (resp. $\lambda^{\ominus} = 1.5$) événement par unité de temps (ms) et $Q_1(0) = Q_{-1}(0) = 10$.

Questions 1.2.3. Simuler les deux files d'attente jusqu'à ce qu'une d'entre elles touche zéro. Puis

1. montrer qu'à la limite Q_1 peut s'approximer par un mouvement brownien arithmétique de drift $\lambda^{\oplus} - \lambda^{\ominus}$ et $\sigma^2 = \lambda^{\oplus} + \lambda^{\ominus}$,
2. simuler la distribution des temps d'atteinte de zéro et la superposer à une simulation brownienne, puis à la distribution théorique brownienne,
3. simuler le temps moyen d'atteinte de zéro d'une des file d'attente et calculer un intervalle de confiance,
4. simuler la moyenne du premier temps d'atteinte de zéro par les files d'attente en fonction de $Q_1(0)$ et $Q_{-1}(0)$,
5. simuler la probabilité que $Q_1(0)$ touche zéro avant $Q_{-1}(0)$ en fonction de $Q_1(0)$ et $Q_{-1}(0)$.

1.2.4 Deuxième modélisation: premières limites non indépendantes, nécessité d'une deuxième limite

Hypothèse 3 (Taux de décès piloté par un processus de Hawkes) Les arrivées surviennent toujours à taux constant : $\lambda^+(t) = \mu^+$, en revanche, le taux de disparition (cancel ou trade) est

auto-excité et mutuellement excité par les arrivées :

$$\lambda^-(t) = \mu^- - \int_{-\infty}^t \phi(t-s) dN_s^+ + \int_{-\infty}^t \phi(t-s) dN_s^-, \quad (1)$$

avec un noyau exponentiel : $\phi(t-s) = \alpha e^{-\beta(t-s)}$, $\alpha, \beta > 0$.

Interprétation: l'intensité de transactions et annulation (i.e. diminution de la file d'attente) diminue avec $dN^+ - dN^-$. Si la file opposée est de taille constante, cela revient à avoir une intensité qui est fonction du déséquilibre acheteurs-vendeurs.

Si la formule en temps continu d'un Hawkes peut paraître compliquée, son implémentation pratique l'est moins. Si on note t_k les instants de saut d'un processus ponctuel M dont l'intensité est

$$v(t) = v_0 + \int_{s < t} \alpha e^{-\beta(t-s)} dM_s, \quad (2)$$

elle s'écrit en discret

$$v(t) = v_0 + \sum_{t_k < t} \alpha e^{-\beta(t-t_k)}.$$

Et son implémentation itérative est simple: on peut écrire $v(t) = v_0 + \Delta\mu_t$, où $\Delta\mu_t$ est multipliée par $\exp -\beta\delta t_k$ et augmentée de $+\alpha$ à chaque fois qu'il y a un saut (c'est facile car à chaque événement on connaît immédiatement $\delta t_k = t_k - t_{k-1}$; en pratique dans les simulations, on déduit $t_k := t_{k-1} + \delta t_k$).

On peut écrire la condition de stationnarité sur ce processus: l'espérance de $\lambda^-(t)$ satisfait une équation de point fixe. Soit $m^- = \mathbb{E}[\lambda^-]$. Comme $\mathbb{E}[\lambda^+] = \mu^+$ à l'équilibre et que $\int_0^\infty \phi(s) ds = \alpha/\beta$, on l'obtient en écrivant l'espérance de (1).

Questions 1.2.4. Notations: $\bar{N}_t$ est la taille de la file d'attente au bid (ordres acheteurs), et $\underline{N}_t$ est la taille de celle à l'ask (ordres vendeurs).

1. Simuler une file d'attente de Hawkes et approcher son intensité stationnaire $\bar{\lambda}^-$,
2. Estimer la distribution des temps d'atteinte de zero par cette file d'attente.
3. Même question lorsqu'on a deux processus de Hawkes couplés pour les intensités des files $\bar{N}_t$ (bid) et $\underline{N}_t$. Cette fois on couple les intensités négatives avec non seulement avec la "taille court terme" de sa file d'attente (comme dans (1)) mais aussi avec celle de la file d'en face:

$$\bar{\lambda}^-(t) = \bar{\mu}^- - \underbrace{\int_{-\infty}^t \phi(t-s) d\bar{N}_s^+ + \int_{-\infty}^t \phi(t-s) d\bar{N}_s^-}_{\text{comme avant}} + \int_{-\infty}^t \phi(t-s) d\underline{N}_s^+ + \int_{-\infty}^t \phi(t-s) d\underline{N}_s^-. \quad (3)$$

4. Estimer la distribution des temps d'atteinte de zero par la première de ces deux files d'attente.
5. Comparer les cas : on s'attend à ce que le temps d'attente pour la première des deux files Hawkes soit inférieur à celui pour une seule file Hawkes qui est lui même à la première de deux files Poisson (session 1.2.3 précédente), et lui même inférieure à une seule Poisson.

1.2.5 Troisième étape de modélisation: deuxième limite

Notons en préambule qu'un processus de Hawkes $(M_t, v(t))_t$ avec un noyau exponentiel (comme celui défini par (2)) est markovien.

On conserve la dynamique (3) pour les premières limites, mais on change les notations car nous n'allons pas avoir que deux processus (quantité à l'ask) $\bar{N} = \bar{N}^+ - \bar{N}^-$ et (quantité au bid) $\underline{N} = \underline{N}^+ - \underline{N}^-$. Nous avons quatre processus :




Figure 4: Un exemple d'illustration pour un processus de Hawkes ($a = 10, \mu^+ = 1.0, \mu^- = 1.1, \alpha = 0.5, \beta = 0.5$)

- les limites 1 et 2 du carnet d'ordre au bid: $N^{+1} = N^{+1,+} - N^{+1,-}$ et $N^{+2} = N^{+2,+} - N^{+2,-}$,
- les limites 1 et 2 du carnet d'ordre à l'ask: $N^{-1} = N^{-1,+} - N^{-1,-}$ et $N^{-2} = N^{-2,+} - N^{-2,-}$.

On conserve donc, pour $i \in \{+1, -1\}$ la dynamique

$$\lambda^{i,-} = \mu^{i,-} - \int_{s < t} \phi(t-s)(dN^{i,+} - dN^{i,-}) + \int_{s < t} \phi(t-s)(dN^{-i,+} - dN^{-i,-}).$$

On conserve les $\lambda^{i,+}$ constants.

Questions 1.2.5.

1. Considérons d'abord que les intensités $(\lambda^{j,\sigma})_{j \in \{+2, -2\}, \sigma \in \{+, -\}}$ des deuxièmes limites sont constantes (comme pour les questions 1.2.3),

- (a) simuler la distribution de N_t^{+2} sachant que $N_t^{+1} = 0$,
- (b) simuler la distribution de N_t^{+2} sachant que $N_t^{-1} = 0$.

Et noter que comme le problème est symétrique les distributions conditionnelles de N_t^{-2} sont les mêmes.

2. En pratique les deuxièmes limites ont tendance à croître, on va modéliser cette dynamique en disant que les diminution de taille de la limite +1 (resp. -1) influence une augmentation de la limite +2 (resp. -2). Typiquement

$$\lambda^{-2,+}(t) = \mu^{-2,+} + \int_{s < t} a e^{-b(t-s)} dN^{-1,-}, \quad (4)$$

où a et b sont des paramètres à choisir.

On conserve constant $\lambda^{-2,-}$ et $\lambda^{+2,-}$.

- (a) simuler la N_t^{+2} sachant que $N_t^{+1} = 0$,
- (b) simuler la distribution de N_t^{+2} sachant que $N_t^{-1} = 0$.

Le but est d'étudier la sensibilité de ces distributions en fonction des valeurs du paramètre a .



Figure 5: Diverses explications pour la section 1.2.4. **ATTENTION: il y a une coquille, $f(\cdot)$ doit être décroissante, ou bien on doit écrire $-f(N)$.**

2 Compléments théoriques

2.1 Pourquoi la probabilité d'atteindre zéro diffère-t-elle entre le processus discret et sa limite brownienne ?

Soit X_t un processus de naissance-mort sur $\mathbb{Z}$ avec taux :

$$X_t \rightarrow X_t + 1 \text{ à taux } \lambda^+, \quad X_t \rightarrow X_t - 1 \text{ à taux } \lambda^-.$$

On note $\rho = \lambda^- / \lambda^+$ et on suppose $X_0 = a > 0$.

1. Processus discret (exact). La probabilité d'atteindre 0 est donnée par :

- Si $\lambda^- \geq \lambda^+$ ($\rho \geq 1$) :

$$P_{\text{discret}}(\text{atteindre } 0) = 1.$$

- Si $\lambda^- < \lambda^+$ ($\rho < 1$) :

$$P_{\text{discret}}(\text{atteindre } 0) = \rho^a = \left(\frac{\lambda^-}{\lambda^+} \right)^a.$$

2. Limite brownienne (processus renormalisé). On pose $Y_t^{(n)} = X_{nt} / \sqrt{n}$. Quand $n \rightarrow \infty$, $Y_t^{(n)}$ converge vers un mouvement brownien avec dérive :

$$dY_t = \mu dt + \sigma dW_t,$$

où $\mu = \lambda^+ - \lambda^-$, $\sigma^2 = \lambda^+ + \lambda^-$.

La probabilité d'atteindre 0 pour ce brownien (partant de $a > 0$) est :

- Si $\mu \leq 0$: $P_{\text{BM}}(\text{atteindre } 0) = 1$.
- Si $\mu > 0$:

$$P_{\text{BM}}(\text{atteindre } 0) = \exp \left(-\frac{2\mu a}{\sigma^2} \right) = \exp \left(-\frac{2(\lambda^+ - \lambda^-)}{\lambda^+ + \lambda^-} a \right).$$

3. Comparaison.

Cas	Discret	Brownien	Concordance
$\lambda^+ > \lambda^-$	$(\lambda^- / \lambda^+)^a$	$\exp \left(-\frac{2(\lambda^+ - \lambda^-)}{\lambda^+ + \lambda^-} a \right)$	Non
$\lambda^+ = \lambda^-$	1	1	Oui
$\lambda^+ < \lambda^-$	1	1	Oui

Conclusion L'approximation par le mouvement brownien **échoue** pour la probabilité d'atteindre un niveau discret fixe comme 0, car elle ignore la structure de réseau sous-jacente. Dans le cas d'une faible dérive vers le haut ($\lambda^+ > \lambda^-$), les deux probabilités sont exponentielles en a , mais avec des taux différents. La seule concordance parfaite a lieu lorsque $\mu \leq 0$ (ruine certaine).

2.2 Hawkes 1d

$$m^- = \mu^- + \frac{\alpha}{\beta} \mu^+ - \frac{\alpha}{\beta} m^-.$$

On résout :

$$m^- \left(1 + \frac{\alpha}{\beta}\right) = \mu^- + \frac{\alpha}{\beta} \mu^+ \implies m^- = \frac{\mu^- + \frac{\alpha}{\beta} \mu^+}{1 + \frac{\alpha}{\beta}}.$$

La condition de stationnarité pour un processus de Hawkes avec noyau signé est que le rayon spectral du noyau soit < 1 . Ici, le noyau intégré vaut α/β en valeur absolue. La condition est donc :

$$\frac{\alpha}{\beta} < 1.$$

Cette condition garantit que les fluctuations du taux de décès ne divergent pas.

2.2.1 Plus de détails

Notons Q_i la taille de la file d'attente numéro $i \in \mathbb{Z}$, avec la convention que lorsque i est positif il s'agit d'une file d'ordres vendeurs (à droite de la Figure 1) et si il est négatif il s'agit d'une file d'ordre acheteurs (à gauche, et en vert sur la figure). En pratique on se contente de $2I$ files d'attente : $i \in \{-I, \dots, +I\}$. Le prix auquel la file d'attente i est attachée est noté p_i ; par convention on note $p_0 = (p_1 + p_{-1})/2$ que l'on appelle le *mid-price*.

Lorsque une des première limite se vide, alors elle peut se remplir de nouveau. Il n'y a deux événements possibles sur une limite vide :

- ou bien elle se remplit avec un ordre d'achat, c'est l'événement *Ask*, qui suit un processus de Poisson $\mathcal{P}^A$ d'intensité λ^A ;
- ou bien elle se remplit avec un ordre de vente, c'est l'événement *Bid*, qui soit un processus de Poisson $\mathcal{P}^B$ d'intensité λ^B .

Attardons-nous sur quelques séquences d'événement particulières, et pour cela utilisons une représentation schématique à une date t_k arbitraire :  est une séquence de trois files à l'achat, une file vide, et trois files à la vente. Si la première limite vendeuse se vide (suite par exemple à un événement d'annulation en t_{k+1}), on se retrouve dans la situation . Si l'événement suivant est une insertion en t_{k+2} de type *Bid* sur la file, alors la nouvelle séquence devrait être  ce qui ne correspond pas à $I = 3$, car on a maintenant 4 files d'attentes à gauche (côté *Bid*) et seulement deux à droite. Il faut alors translater les quantités vers la gauche en générant une nouvelle quantité pour Q_3 (ici en orange) et en "oubliant" Q_{-4} ; le modèle devient, disons en t_{k+2}^+ : .

Formellement, on a effectué les opérations suivantes en passant de t_{k+2} à t_{k+2}^+ :

- en ce qui concerne les quantités: $Q_i(t_{k+2}^+) = Q_{i+1}(t_{k+2})$ pour $i \in \{-I, \dots, I-1\}$, et $Q_3(t_{k+2}^+)$ (en orange) est tiré aléatoirement selon une loi $\mathcal{L}_3^Q$.
- et en ce qui concerne les prix $p_i(t_{k+2}^+) = p_{i+1}(t_{k+2})$ pour $i \in \{-I, \dots, I-1\}$, et $p_I(t_{k+2}^+) = p_{I-1}(t_{k+2}^+) + \delta^p$, où δ^p est l'incrément de prix standard, le pas de cotation.

Une famille de modèles. Un modèle QR (comme Queue Reactive) est donc défini par

- I le nombre de ses files d'attente,
- en notant $\mathbf{Q} = (Q_{-I}, \dots, Q_I)$ le vecteur des $2I$ quantités des files d'attentes, un modèle QR a une fonction $f(\mathbf{Q}, i) : \mathbb{R}^{+2I} \times \{-I, \dots, I\} \rightarrow \mathbb{Z}$ qui associe à une forme de carnet d'ordre et pour la file d'attente numéro i un indicateur discret.

– Un exemple trivial est une constante qui ne dépend que de l'indice:

$$\forall i : f_c(\mathbf{Q}, i) = \ell_i.$$

– Un exemple un peu plus sophistiqué est l'*imbalance* pour les premières limites et la taille relative pour les autres, c'est-à-dire (avec $\lfloor \cdot \rfloor_{1/10}$ la fonction d'arrondi au 10ème):

$$f_{imb}(\mathbf{Q}, \pm 1) = \pm \left\lfloor \frac{Q_{-1} - Q_1}{Q_{-1} + Q_1} \right\rfloor_{1/10} \in \{-1, -0.9, \dots, 0.9, 1\},$$

$$\text{et pour } i > 1 : f_{imb}(\mathbf{Q}, \pm i) = \left\lfloor \frac{Q_i}{\sum_{j=1}^I Q_{\pm j}} \right\rfloor_{1/10} \in \{0, \dots, 0.9, 1\}.$$

- pour chaque file d'attente i , ses cinq fonctions d'intensités $\lambda_i^+, \lambda_i^-, \lambda_i^T, \lambda_i^B, \lambda_i^A$ qui vont de

- les lois $\mathcal{L}_{-I}^Q$ et $\mathcal{L}_I^Q$ qui servent à tirer les quantités des files d'attente qui “apparaissent” par la gauche et par la droite.

On peut imaginer des modèles QR plus compliqué, avec deux événements de plus pour les premières limites : *consommation totale de la limite par une transaction*, avec leur propres intensités λ^{TC} (comme *Total Consumption*).

Le principe des modèles QR est que

1. ils modélisent les événements qui se produisent sur chaque file d'attente par des processus de Poisson,
2. dont l'intensité est *sans mémoire*: elle ne dépend que de la forme du carnet d'ordres.

2.3 Simulations

Nous commencerons par un modèle simple, lorsque $I = 1$, c'est-à-dire que l'on ne modélise que la première limite à l'achat et à la vente. On pourra utiliser un modèle QR constant, et un modèle QR d'imbalance. Suivant la vitesse de l'avancement les étudiants pourront complexifier les modèles pour les rendre plus réalistes (notamment un modèle où les intensités sont influencées par l'*imbalance* du carnet d'ordre).

2.3.1 Intervalles de confiance d'événements communs

a. Probabilité d'occurrence du prochain événement. Une première quantité d'intérêt est la probabilité que le prochain événement sur une file d'attente donnée soit d'un certain type (par exemple une annulation ou une transaction). Cela peut s'obtenir par simulation ainsi qu'en formule fermée.

b. Liquidité. La liquidité est caractérisée par la forme du carnet d'ordres, on va donc s'intéresser à la forme stationnarisée du carnet: quelle est la limite $\mathbf{Q}(+\infty) = (Q_{-I}(+\infty) \dots, Q_I(+\infty))$, avec ses intervalles de confiance?

c. Impact du point de départ sur le prix. Une autre quantité d'intérêt est le prix à l'infini sachant le prix de départ et un état du carnet. Cela permet de mettre en place des stratégies de trading optimal (cf. [LN19] ou la partie des applications numériques de [ML24]).

2.3.2 Événements rares

a. Consommation totale de la première limite. Un événement important est la consommation totale de la meilleure limite à l'achat ou à la vente. Dans ce cas la seconde meilleure limite est *promue* première meilleure limite ; une question importante est la taille de cette seconde limite conditionnellement à la consommation totale de la première limite.

b. Impact d'une série d'événements sur la forme du carnet d'ordres. Une autre question à laquelle les étudiants pourront répondre est l'impact sur le carnet d'ordre d'une séquence particulière.

2.4 Modèle probabiliste (v1).

Notations. At any time t , the orderbook $\text{LOB}(t)$ is projected on a state $f(\text{LOB}) = (\text{Imb}, n)$ where

$$\text{Imb} = \frac{Q^B - Q^A}{Q^B + Q^A}$$

and n is the number of empty prices between the best bid and the best ask.

The possible events occurring on the orderbook are reduced to

$$\mathcal{E} := \{L, C, T\} \times \{B_\ell, A_\ell\}^{1 \leq \ell \leq \bar{L}} \cup \{+, -\} \times \llbracket -N, N \rrbracket.$$

The meaning is: $\{L, C, T\}$ are (insert) Limit order, Cancel order, Transaction either on the ℓ th $\{B_\ell, A_\ell\}$ (or the second $\{B_1, A_1\}$) Bid or Ask. Another type of event is the appearance of a passing Buying (+) or Selling (−) order inside the spread at a distance $n \in \llbracket -N, N \rrbracket$ to the mid-price.

The QR model is made of the specific choice of $f(\cdot)$ and $\mathcal{E}$, it assumes that events of $\mathcal{E}$ occur following Poisson processes that are conditionally independent with respect to $f(\text{LOB})$. The natural notation for their intensities (that is enough to specify them) is $\lambda^e(f(\text{LOB}), \ell(e)) \in \mathbb{R}^+$, where $e \in \mathcal{E}$ and $\ell(e)$ is the index of the queue. In our specific case $\lambda^e(f(\text{LOB}), \ell(e)) = \lambda^e(\text{Imb}, n; \ell(e))$. The sum of the intensities of all events possibly following a state of (Imb, n) is

$$\Lambda(\text{Imb}, n) = \sum_{e \in \mathcal{E}} \lambda^e(\text{Imb}, n; \ell(e)).$$

We now need a notation of the stopping time at which events occur on queue ℓ . Let set t_k^e these ordered stopping times and set $\Delta t_k^e = t_k^e - t_{k-1}^{e'} \in \mathcal{F}_k$, where e' is the event type that occurred just before e . The set of all stopping times is $\mathcal{T}$.

We use the notation $\ell(e)$ because the limit on which the event occurred is specified in e : either it is an event of type $\{L, C, T\} \times \{B_\ell, A_\ell\}^{1 \leq \ell \leq \bar{L}}$ and in such a case $\ell(e) = \ell$ if it happens on the ask side, $\ell(e) = -\ell$ otherwise; either the type of the event is $\{+, -\} \times \llbracket -N, N \rrbracket$ and in such a case $\ell(e) = 0$ if $n = 0$ and $\ell(e) = 1/n$ otherwise. We take this encoding just to ensure to not mix the empty limits with the others.

To ease the notation, we use $\mathcal{K}^e(\text{Imb}, n)$ for the set of time indexes k such that the an event $e \in \mathcal{E}$ (on limit $\ell(e)$) at time t_k^e while the orderbook state was $f(\text{LOB}) = (\text{Imb}, n)$ at the previous stopping time $t_{k-1}^{e'}$. The set of indexes of stopping times immediately after a state (Imb, n) is $\mathcal{K}(\text{Imb}, n) = \cup_e \mathcal{K}^e(\text{Imb}, n)$. More formally

$$\mathcal{K}^e(\text{Imb}, n) = \{k : t_k^{e'} \in \mathcal{T}, (e' = e) \wedge (\exists e'' : f(\text{LOB}(t_{k-1}^{e'')}) = (\text{Imb}, n))\}.$$

Namely “the set of indexes of stopping times $t_k^{e'}$ such that the corresponding event is e and at the previous stopping time the state was (Imb, n) ”.

Estimation of the intensities of events. We can now express two main variables under our QR model:

- The intensity $\Lambda(\text{Imb}, n)$ drives the occurrence of the next event:

$$\Delta t_k^e | \mathcal{K}(\text{Imb}, n) \sim \text{Exp } \Lambda(\text{Imb}, n) \quad (5)$$

because this inter-events time is the minimum (i.e. the first observed event) amongst all the possible ones

$$\Delta t^e \sim \min_{e' \in \mathcal{E}} \text{Exp } \lambda^{e'}(\text{Imb}, n; \ell(e)).$$

- The probability $q^{e, \ell}$ of observing a specific type of event e on ℓ immediately after a state (Imb, n) is simply

$$q^e = \frac{\lambda^e(\text{Imb}, n; \ell(e))}{\Lambda(\text{Imb}, n)}. \quad (6)$$

The first relation implies that

$$\Lambda(\text{Imb}, n) = (\mathbb{E}(\Delta t_k^e | k \in \mathcal{K}(\text{Imb}, n)))^{-1}.$$

It allows to build the estimate

$$\hat{\Lambda}(\text{Imb}, n) = \left(\frac{1}{\#\mathcal{K}(\text{Imb}, n)} \sum_{\substack{e \in \mathcal{E} \\ k \in \mathcal{K}^e(\text{Imb}, n)}} \Delta t_k^e \right)^{-1}.$$

And the second one allows to build the estimate of an intensity for one given type of event e given the state (Imb, n) :

$$\hat{\lambda}^e(\text{Imb}, n; \ell(e)) = \hat{\Lambda}(\text{Imb}, n) \cdot \underbrace{\frac{\#\mathcal{K}^e(\text{Imb}, n)}{\#\mathcal{K}(\text{Imb}, n)}}_{\hat{q}^e}.$$

Simulations. If we want to simulate this QR model, we need to start from an orderbook LOB_0 that can be arbitrary or drawn for a given distribution. Then the dynamics are the following:

1. compute the state $(\text{Imb}, n) := f(\text{LOB})$ at current t_k ,
2. draw $\#\mathcal{E}|_{\text{LOB}}$ inter-event times candidates

$$\forall e : \Delta \tau^e \sim \text{Exp } \lambda^e(\text{Imb}, n; \ell(e)).$$

3. The one to be simulated is the minimum amongst them, corresponding to the event

$$e^* := \arg \min_e \Delta \tau^e,$$

it means to set $\Delta t_{k+1}^{e^*} = \Delta \tau^{e^*}$ and the next stopping time $t_{k+1}^{e^*} = t_k + \Delta t_{k+1}^{e^*}$.

4. Implement the corresponding change on the orderbook:

$$\text{LOB}(t_{k+1}) = \Psi(\text{LOB}(t_k, e^*)).$$

And iterate.

The only missing point is the function $\Psi(\text{LOB}, e)$: the transition from orderbook LOB to another orderbook given the transition (i.e. event) e :

$e = (s, z) \in \{+, -\} \times \llbracket -n, n \rrbracket$: these events occur only if there is at most $n+n'$ empty prices strictly between the best bid and the best ask. The transition is the following:

Add a buying (if $s = +$) or a selling (if $s = -$) quantity at z ticks from the mid-price.

$e = (t, s) \in \{L, C, T\} \times \{B_\ell, A_\ell\}^{1 \leq \ell \leq \bar{L}}$: insert (respectively cancel, or generate a trade) an order in queue s if $t = L$ (respectively if $e = C$, if $e = T$).

Remark that: if as a consequence, this queue is now empty and it was the first limit, an empty price appears in the limit orderbook.

In practice, we need to be sure that we have the correct set of possible events $\mathcal{E}|_{\text{LOB}}$ (and their intensities) given a limit orderbook LOB . It can be done thanks to the mapping f from any orderbook LOB to the imbalance and the number of empty prices between the best bid and best ask; $f(\text{LOB}) = (\text{Imb}, n)$. The best bid and best ask prices (p^B, p^A) and the tick size δ are needed too (they can be read in the orderbook):

- events $\{L, C, T\} \times \{B_\ell, A_\ell\}^{1 \leq \ell \leq \bar{L}}$ are always candidates,
- if $n > 0$ then events $\{+, -\} \times \llbracket -n, n \rrbracket$ are possible candidates too, where:
 - if $(p^A - p^B)/\delta$ is even $n \in \llbracket -(p^A - p^B)/(2\delta), (p^A - p^B)/(2\delta) \rrbracket \setminus \{0\}$,
 - else $n \in \llbracket -(p^A - p^B - 1)/(2\delta), (p^A - p^B - 1)/(2\delta) \rrbracket$.

2.5 Modèle probabiliste (v2).

On se place dans un espace probabilisé $(\Omega, \mathcal{A}, \mathbb{P})$. Le carnet d'ordre est donnée par le processus de saut markovien $\mathbf{Q}(t) = (Q_{-I}(t), \dots, Q_{-1}(t), Q_1(t), \dots, Q_I(t))$, on note la filtration associée $\mathcal{F}_t = \sigma(\mathbf{Q}(s), 0 \leq s \leq t)$ et les temps de sauts aléatoires $(T_i)_{i \in \mathbb{N}}$. On introduit aussi $(E_i)_{i \in \mathbb{N}}$ $(q_i)_{i \in \mathbb{N}}$ qui sont respectivement l'événement qui s'est produit à l'instant T_i ainsi que l'indice de la file correspondante. On a donc:

$$\forall j \in \{-I, \dots, -1, 1, \dots, I\} \quad T_i^j | \mathbf{Q}(T_{i-1}) \sim \text{Exp}(\Lambda(\mathbf{Q}(T_{i-1}), j))$$

$$T_i | \mathbf{Q}(T_{i-1}) \sim \min \{T_i^j, j \in \{-I, \dots, -1, 1, \dots, I\}\}$$

$$q_i | \mathbf{Q}(T_{i-1}) \sim \text{argmin} \{T_i^j, j \in \{-I, \dots, -1, 1, \dots, I\}\}$$

$$E_i | \mathbf{Q}(T_{i-1}) \sim \sum_{e \in g(\mathbf{Q}_{T_{i-1}}, q_i)} w_e \delta_e, \text{ avec } w_e = \frac{\lambda^e(\mathbf{Q}(T_{i-1}), q_i)}{\Lambda(\mathbf{Q}(T_{i-1}), q_i)}$$

$$\mathbf{Q}(T_i) = \begin{cases} \text{si } E_i \in \{+, -\}, (Q_j(T_{i-1}) \pm \delta_{q_i}(j))_{j \in \{-I, \dots, -1, 1, \dots, I\}} \\ \text{si } E_i \in \{A, B\}, \left\{ \begin{array}{l} \text{si } (1 - 2\delta_B(E_i)) q_i > 0, (Q_j(T_{i-1}) + \delta_{q_i}(j))_{j \in \{-I, \dots, -1, 1, \dots, I\}} \\ \text{sinon} \left\{ \begin{array}{l} \text{si } q_i > 0, \left\{ \begin{array}{l} \mathbf{Q}^{\text{Bid}}(T_i) = (Q_j(T_{i-1}))_{j \in \{-I+q_i, \dots, -1, 1, \dots, q_i\}} \\ \mathbf{Q}^{\text{Ask}}(T_i) = \left((Q_j(T_{i-1}))_{j \in \{q_i+1, I\}}, \underbrace{\mathcal{L}^{\mathbf{Q}}, \dots, \mathcal{L}^{\mathbf{Q}}}_{q_i \text{ samples}} \right) \\ \mathbf{Q}(T_i) = (\mathbf{Q}^{\text{Bid}}(T_i), \mathbf{Q}^{\text{Ask}}(T_i)) \end{array} \right. \\ \text{si } q_i < 0, \left\{ \begin{array}{l} \mathbf{Q}^{\text{Bid}}(T_i) = \left(\underbrace{\mathcal{L}^{\mathbf{Q}}, \dots, \mathcal{L}^{\mathbf{Q}}}_{-q_i \text{ samples}}, (Q_j(T_{i-1}))_{j \in \{-I, q_i-1\}} \right) \\ \mathbf{Q}^{\text{Ask}}(T_i) = (Q_j(T_{i-1}))_{j \in \{q_i, \dots, -1, 1, \dots, I+q_i\}} \\ \mathbf{Q}(T_i) = (\mathbf{Q}^{\text{Bid}}(T_i), \mathbf{Q}^{\text{Ask}}(T_i)) \end{array} \right. \end{array} \right. \end{array} \right. \end{cases}$$

En posant $\Lambda(\mathbf{Q}) = \sum_j \Lambda(\mathbf{Q}, j)$ on remarque que: $q_i \sim \sum_j \frac{\Lambda(\mathbf{Q}, j)}{\Lambda(\mathbf{Q})} \delta_j$ et $T_i | q_i \sim \text{Exp}(\Lambda(\mathbf{Q}, q_i))$

2.6 Implémentation.

$m(\mathbf{Q})$ est la meilleure limite non vide côté Bid, et $M(\mathbf{Q})$ côté Ask. Cette implémentation de la fonction f est : l'imbalance pour les premières limites non vides, et la taille de la queue sinon. Pour des raisons d'homogénéité, nous pourrions prendre $Q_i / \sum_j Q_{\text{sign}(i)j}$ au lieu de Q_i .

Model

$$\text{On pose } \begin{cases} m(\mathbf{Q}) \triangleq \operatorname{argmax} \{i \in \{-I, \dots, -1\} \text{ tq: } Q_i > 0\} \\ M(\mathbf{Q}) \triangleq \operatorname{argmin} \{i \in \{1, \dots, I\} \text{ tq: } Q_i > 0\} \end{cases}$$

$$f(\mathbf{Q}, i) \triangleq \begin{cases} \frac{Q_{M(\mathbf{Q})} - Q_{m(\mathbf{Q})}}{Q_{M(\mathbf{Q})} + Q_{m(\mathbf{Q})}} \times \operatorname{sign}(i) \text{ pour } i \in \{m(\mathbf{Q}), \dots, -1, 1, \dots, M(\mathbf{Q})\} \\ Q_i \text{ pour } i \notin \{m(\mathbf{Q}), \dots, -1, 1, \dots, M(\mathbf{Q})\} \end{cases}$$

On estime à partir des données $\lambda_{\text{Imb}}^\pm, \lambda_{\text{Imb}}^A, \lambda_{\text{Imb}}^B$ et $\forall i \in \{2, \dots, I\} \lambda_i^\pm$.

Algorithm 1 SampleQRStep

Input: $\lambda_{\text{Imb}}^\pm, \lambda_{\text{Imb}}^A, \lambda_{\text{Imb}}^B, \forall i \in \{2, \dots, I\} \lambda_i^\pm, \mathcal{L}^{\mathbf{Q}}$, and $\mathbf{Q}$

Output: Updated $\mathbf{Q}$, Δt , event, event-queue

```

for  $i \in \{-I, \dots, -1, 1, \dots, I\}$  do
  if  $i \notin \{m(\mathbf{Q}), \dots, 1, -1, \dots, M(\mathbf{Q})\}$  then
     $e_i, q_i \leftarrow \{+, -\}, |i|$ 
  else if  $i \in \{m(\mathbf{Q}), M(\mathbf{Q})\}$  then ▷  $Q_i$  is best bid/ask
     $e_i, q_i \leftarrow \{+, -\}, \text{Imb}$ 
  else ▷  $Q_i$  is empty
     $e_i, q_i \leftarrow \{A, B\}, \text{Imb}$ 
  end if
   $\Lambda, p_i \leftarrow \sum_{e \in e_i} \lambda_{q_i}^e(f(\mathbf{Q}, i)), \left\{ \frac{\lambda_{q_i}^e(f(\mathbf{Q}, i))}{\Lambda} \right\}_{e \in e_i}$ 
   $\Delta t_i \leftarrow -\log(\text{Ran}()) * \Lambda$  ▷  $\text{Ran}()$  is an oracle that samples Uniform(0, 1)
end for
 $j \leftarrow \operatorname{argmin} \{\Delta t_i, i \in \{-I, \dots, -1, 1, \dots, I\}\}$ 
 $e \leftarrow \text{Choice}(e_j, p_j)$  ▷  $\text{Choice}()$  is an oracle that samples from  $e_j$  with probabilities  $p_j$ 
 $\mathbf{Q} \leftarrow \text{UpdateLOB}(\mathbf{Q}, e, j, \mathcal{L}^{\mathbf{Q}})$ 
Return:  $\mathbf{Q}, \Delta t_j, e, j$ 

```

Algorithm 2 UpdateLOB

Input: $\mathbf{Q}, e, j, \mathcal{L}^{\mathbf{Q}}$,

Output: Updated $\mathbf{Q}$

```

Apply event  $e$  to  $Q_j$ 
if  $e == A$  and  $j < 0$  then
   $\mathbf{Q}^{\text{Ask}} \leftarrow \{Q_j, \dots, Q_{-1}, Q_1, \dots, Q_{I+j}\}$ 
   $\mathbf{Q}^{\text{Bid}} \leftarrow \{\mathcal{L}^{\mathbf{Q}}(), \dots, \mathcal{L}^{\mathbf{Q}}(), Q_{-I}, \dots, Q_{j-1}\}$  ▷ Each  $\mathcal{L}^{\mathbf{Q}}()$  is an indepdant sample
   $\mathbf{Q} \leftarrow \{\mathbf{Q}^{\text{Bid}}, \mathbf{Q}^{\text{Ask}}\}$ 
else if  $e == B$  and  $j > 0$  then
   $\mathbf{Q}^{\text{Bid}} \leftarrow \{Q_{-I+j}, \dots, Q_{-1}, Q_1, \dots, Q_j\}$ 
   $\mathbf{Q}^{\text{Ask}} \leftarrow \{Q_{j+1}, \dots, Q_I, \mathcal{L}^{\mathbf{Q}}(), \dots, \mathcal{L}^{\mathbf{Q}}()\}$  ▷ Each  $\mathcal{L}^{\mathbf{Q}}()$  is an indepdant sample
   $\mathbf{Q} \leftarrow \{\mathbf{Q}^{\text{Bid}}, \mathbf{Q}^{\text{Ask}}\}$ 
end if
Return:  $\mathbf{Q}$ 

```


Références

- [LL18] Lehalle, Charles-Albert, and Sophie Laruelle. *Market microstructure in practice*. World Scientific, 2018.
- [HLR15] Huang, Weibing, Charles-Albert Lehalle, and Mathieu Rosenbaum. *Simulating and analyzing order book data: The queue-reactive model*. Journal of the American Statistical Association 110, no. 509 (2015): 107-122.
- [LN19] Lehalle, Charles-Albert, and Eyal Neuman. *Incorporating signals into optimal trading*. Finance and Stochastics 23 (2019): 275-311.
- [ML24] Mounjid, Othmane, and Charles-Albert Lehalle. *Improving reinforcement learning algorithms: Towards optimal learning rate policies*. Mathematical Finance 34, no. 2 (2024): 588-621.

A Numerical values

One moving queue. we set $Q_1 \equiv \bar{Q}$ (ask side) constant and the intensities (for the bid side):

	λ^T	λ^C	λ^L
1	1	1	3
$[-\theta, \theta]$	1	1	2
-1	3	2	1

There is a question about $\bar{Q}$ and T (total simulation time). There is a relation coming from: *if I enter the negative regime with a quantity q , I go to zero with an average speed of $\lambda^T + \lambda^C - \lambda^L$* . It implies that I will survive on average $q/(\lambda^T + \lambda^C - \lambda^L)$.

There is another question: *if I give you K Poisson processes, how to get the δt to the first occurrence ?*